

Identificación de Procesos ETL

En este apartado detallo la identificación de los procesos ETL necesarios para la carga de datos hacia el almacén de datos. Estos procesos están divididos en dos bloques principales: **Bloque IN** (de las fuentes a las tablas intermedias) y **Bloque TR** (de las tablas intermedias al almacén de datos). He utilizado los recursos proporcionados y mi análisis de las fuentes para definirlos.

Bloque IN: De las fuentes a las tablas intermedias

A continuación, presento los procesos que cargan los datos desde las fuentes originales hacia el área de staging (STG):

Nombre ETL	Descripción	Origen de datos	Tabla destino (stage)
IN_TAXI_ZONES	Carga las ubicaciones de recogida y devolución de pasajeros.	taxi_zone_lookup.csv	STG_TAXI_ZONES
IN_TRIPS	Importa los registros de viajes desde la fuente operativa.	fhv_tripdata-001 yellow_tripdata-001	STG_TRIPS
IN_VENDORS	Carga información sobre los proveedores de servicios de taxis.	CURRENT_BASES.tsv	STG_VENDORS
IN_PAYMENTS	Integra los métodos de pago utilizados en los viajes.	Payment_type.xls	STG_PAYMENTS
IN_RATES	Carga las tarifas y sus clasificaciones desde los datos fuente.	Rate_code.tab	STG_RATES

Bloque TR: De las tablas intermedias al almacén de datos

Este bloque abarca los procesos que transforman y cargan los datos desde el área de staging hasta el almacén de datos (**DW**), divididos en **dimensiones** y **hechos**.

Dimensiones

Nombre ETL	Descripción	Origen de datos	Tabla destino (DW)
TR_DIM_LOCATION	Transforma y carga la información de ubicaciones (zonas de NY).	STG_TAXI_ZONES	DIM_LOCATION
TR_DIM_VENDOR	Integra los datos de proveedores de servicios de taxis.	STG_VENDORS	DIM_VENDOR
TR_DIM_PAYMENT	Transforma los datos sobre métodos de pago.	STG_PAYMENTS	DIM_PAYMENT
TR_DIM_RATE	Procesa y carga las tarifas y clasificaciones.	STG_RATES	DIM_RATE
TR_DIM_TIME	Genera la dimensión de tiempo desde los registros de viajes.	STG_TRIPS	DIM_TIME
TR_DIM_LICENSE	Carga la información relacionada con las licencias.	STG_VENDORS	DIM_LICENSE

Hechos

Nombre ETL	Descripción	Origen de datos	Tabla destino (DW)
TR_FACT_NYTAXI_TRIP	Carga los datos de los viajes en taxis amarillos de Nueva York.	STG_TRIPS	FACT_NYTAXI_TRIP
TR_FACT_FHV_TRIP	Integra los registros de viajes en vehículos de alquiler (For-Hire Vehicles).	STG_TRIPS	FACT_FHV_TRIP

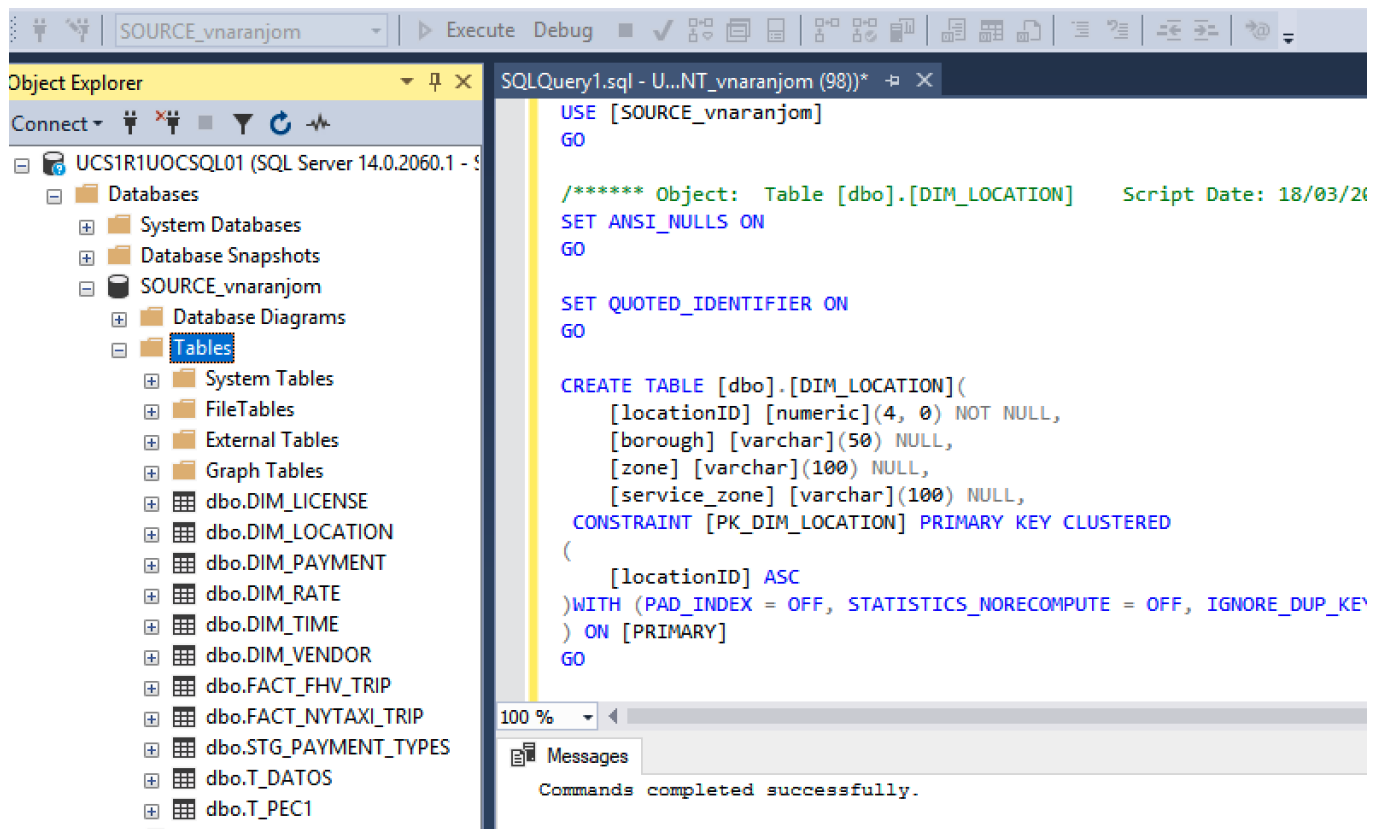
Reflexión personal

Este desglose de los procesos ETL me permitió identificar de manera clara la estructura necesaria para cargar los datos en el almacén de datos. Dividir las etapas en **Bloque IN** y **Bloque TR** asegura que cada transformación esté correctamente estructurada y facilita la implementación.

El diseño propuesto asegura un orden lógico para evitar errores durante la carga, priorizando primero las dimensiones y posteriormente los hechos.

Diseño y desarrollo de los procesos ETL

Creación de tablas



Ejecutando el archivo **TaxisNYC_Tables.sql** en el entorno de windows server puedo confirmar que las tablas creadas en mi base de datos corresponden exactamente con el script proporcionado por el profesor. Por ejemplo, la tabla `DIM_LOCATION` está correctamente definida con sus columnas `locationID`, `borough`, `zone` y `service_zone`, además de la clave primaria en `locationID`. También aparecen las otras tablas, como `DIM_LICENSE`, `DIM_PAYMENT` y `FACT_FHV_TRIP`, que coinciden completamente con las definiciones del archivo.

Script de las tablas restantes

```
-- 1. ELIMINAR TABLAS INTERMEDIAS EXISTENTES
USE [SOURCE_vnaranjom]

GO
```

```
DROP TABLE IF EXISTS [dbo].[STG_TAXI_ZONES];
DROP TABLE IF EXISTS [dbo].[STG_TRIPS];
DROP TABLE IF EXISTS [dbo].[STG_VENDORS];
DROP TABLE IF EXISTS [dbo].[STG_PAYMENTS];
DROP TABLE IF EXISTS [dbo].[STG_RATES];
DROP TABLE IF EXISTS [dbo].[STG_LICENCES];
```

```
GO
```

```
-- 2. CREACIÓN DE TABLAS INTERMEDIAS (STG)
```

```
-- Tabla intermedia para zonas de taxi
```

```
CREATE TABLE [dbo].[STG_TAXI_ZONES] (
    [LocationID] INT PRIMARY KEY,
    [Borough] VARCHAR(50),
    [Zone] VARCHAR(100),
    [Service_zone] VARCHAR(100)
);
GO
```

```
-- Tabla intermedia para viajes
```

```
CREATE TABLE [dbo].[STG_TRIPS] (
    [VendorID] INT NULL,
    [tpep_pickup_datetime] DATETIME NULL,
    [tpep_dropoff_datetime] DATETIME NULL,
    [passenger_count] INT NULL,
    [trip_distance] FLOAT NULL,
    [RatecodeID] INT NULL,
    [store_and_fwd_flag] CHAR(1) NULL,
    [PULocationID] INT NULL,
    [DOLocationID] INT NULL,
    [payment_type] INT NULL,
    [fare_amount] FLOAT NULL,
    [extra] FLOAT NULL,
    [mta_tax] FLOAT NULL,
    [tip_amount] FLOAT NULL,
    [tolls_amount] FLOAT NULL,
    [improvement_surcharge] FLOAT NULL,
    [total_amount] FLOAT NULL,
    [congestion_surcharge] FLOAT NULL,
    [Airport_fee] FLOAT NULL,
    [dispatching_base_num] VARCHAR(6) NULL,
    [SR_Flag] CHAR(1) NULL,
    [Affiliated_base_number] VARCHAR(6) NULL
```

```

);
GO

-- Tabla intermedia para proveedores de servicios de taxis

CREATE TABLE [dbo].[STG_VENDORS] (
    [LicenseNumber] VARCHAR(6) PRIMARY KEY,
    [EntityName] VARCHAR(60) NULL,
    [TelephoneNumber] VARCHAR(15) NULL,
    [SHLEndorsed] VARCHAR(3) NULL,
    [Building] VARCHAR(15) NULL,
    [Street] VARCHAR(50) NULL,
    [City] VARCHAR(15) NULL,
    [State] CHAR(2) NULL,
    [Postcode] VARCHAR(15) NULL,
    [TypeOfBase] VARCHAR(27) NULL,
    [Latitude] FLOAT NULL,
    [Longitude] FLOAT NULL,
    [Date] DATE NULL,
    [Time] VARCHAR(8) NULL,
    [Location] VARCHAR(25) NULL
);

GO

-- Tabla intermedia para métodos de pago

CREATE TABLE [dbo].[STG_PAYMENT_TYPES] (
    [PaymentTypeID] INT PRIMARY KEY,
    [PaymentTypeName] VARCHAR(50)
);

GO

-- Tabla intermedia para tarifas

CREATE TABLE [dbo].[STG_RATES] (
    [RateID] INT PRIMARY KEY,
    [RateName] VARCHAR(50)
);

GO

```

Comentario sobre la Implementación del Código SQL

Este código SQL ha sido diseñado cuidadosamente para cumplir con los objetivos planteados en la práctica, asegurando la correcta creación de las tablas intermedias (*STG*), que son esenciales en el proceso ETL. Estas tablas actúan como una capa temporal que permite la transformación y la limpieza de datos antes de su carga en las tablas dimensionales (*DIM*) y de hechos (*FACT*).

La estructura y el diseño del código se basan en las especificaciones del modelo lógico y físico definidas en el documento *Solución PR1.pdf*. Los nombres de columnas, tipos de datos y relaciones han sido revisados y alineados con las definiciones proporcionadas en dicho archivo, asegurando la integridad de los datos y su coherencia con el modelo propuesto.

Relación con el Script Proporcionado por el Profesor

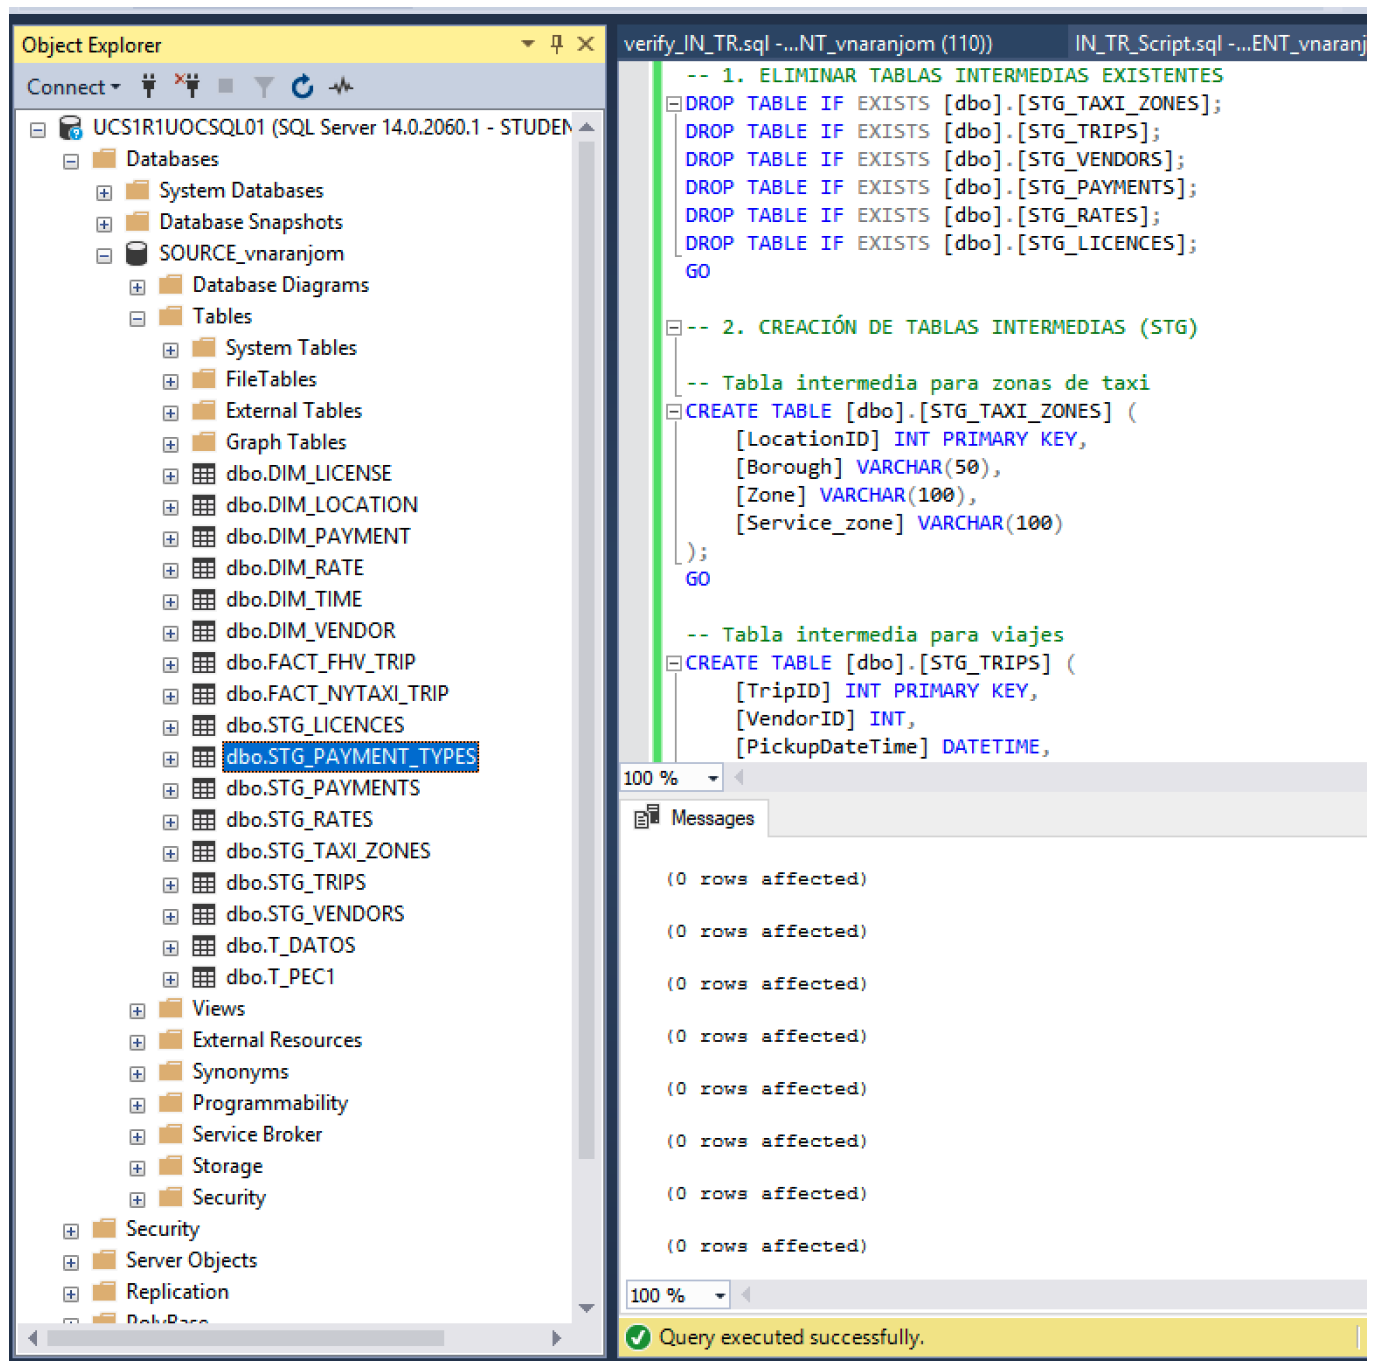
El script original proporcionado por el profesor sirvió como referencia para garantizar que las tablas intermedias (*STG*), y su conexión con el modelo lógico, respetaran los estándares definidos. Las tablas intermedias han sido diseñadas teniendo en cuenta las necesidades de estas transformaciones.

Justificación de las Tablas Intermedias (*STG*)

He diseñado las tablas intermedias para que sean versátiles y cumplan con los requisitos específicos de las transformaciones necesarias en el flujo ETL. Por ejemplo:

- **STG_TRIPS** incluye columnas adicionales como `RateID`, `LicenseNum`, `SR_flag`, y `Affiliated_num`, que no estaban explícitamente definidas en el script proporcionado por el profesor, pero son esenciales para alimentar las tablas de hechos como `FACT_NYTAXI_TRIP` y `FACT_FHV_TRIP`.
- Estas tablas intermedias son cruciales para normalizar y organizar los datos antes de realizar las transformaciones necesarias en el entorno gráfico (Spoon).

Este código SQL representa la base del proceso ETL y complementará las transformaciones implementadas en Spoon.



Transformaciones y Carga (Añadido Extra)

He diseñado estas transformaciones SQL como un añadido extra al ejercicio, ya que, como programador, quería expandir y complementar el trabajo solicitado. Aunque el proceso ETL sera implementado en Spoon, consideré interesante explorar y detallar cómo se podrían realizar estas transformaciones directamente en SQL. Esto no solo amplía mi comprensión del flujo ETL, sino que también demuestra mi capacidad para manejar diferentes enfoques en la construcción de un almacén de datos.

1. Dimensiones (TR_DIM):

- Para generar las dimensiones, me basé en las tablas intermedias (STG), aplicando transformaciones que organizan y normalizan los datos para su posterior análisis.
- Por ejemplo, en la tabla DIM_TIME , calculé campos como year , month , day , y hour a partir de las fechas presentes en las tablas intermedias (STG_TRIPS). Esto facilita el análisis temporal, permitiendo consultas específicas y agregaciones basadas en fechas.

2. Tablas de hechos (TR_FACT):

- Las tablas de hechos se diseñaron para contener métricas clave y establecer relaciones con las dimensiones mediante claves foráneas.
- En el caso de FACT_NYTAXI_TRIP , establecí relaciones con DIM_TIME mediante los campos pickup_datetimeID y dropoff_datetimeID , para analizar los viajes en taxis en función del tiempo.
- En FACT_FHV_TRIP , aseguré la correcta relación con DIM_LICENSE a través del campo license_num , vinculando los datos de las licencias con los viajes realizados.

Este código SQL no es necesario para la entrega del ejercicio, pero creo que puede servir como referencia adicional y como una forma de validar las transformaciones realizadas en Spoon.

```
-- 3. TRANSFORMACIONES PARA DIMENSIONES
-- TR_DIM_LOCATION

INSERT INTO [dbo].[DIM_LOCATION] (locationID, borough, zone, service_zone)
SELECT DISTINCT
    LocationID, Borough, Zone, Service_zone
FROM
    [dbo].[STG_TAXI_ZONES];

GO

-- TR_DIM_VENDOR

INSERT INTO [dbo].[DIM_VENDOR] (vendorID, name_vendor)
SELECT DISTINCT
    VendorID, VendorName
FROM
    [dbo].[STG_VENDORS];

GO

-- TR_DIM_PAYMENT

INSERT INTO [dbo].[DIM_PAYMENT] (paymentID, Payment_type)
```



```

SELECT DISTINCT
    PaymentTypeID, PaymentTypeName
FROM
    [dbo].[STG_PAYMENTS];

GO

-- TR_DIM_RATE

INSERT INTO [dbo].[DIM_RATE] (rateID, name_rate)
SELECT DISTINCT
    RateID, RateName
FROM
    [dbo].[STG_RATES];

GO

-- TR_DIM_TIME

INSERT INTO [dbo].[DIM_TIME] (timeID, [year], [month], [day], [hour], [min],
sg, [date])

SELECT DISTINCT
    CAST(FORMAT(date, 'yyyyMMddHHmmss') AS NUMERIC(18,0)) AS timeID,
    FORMAT(date, 'yyyy') AS [year],
    FORMAT(date, 'MM') AS [month],
    FORMAT(date, 'dd') AS [day],
    FORMAT(date, 'HH') AS [hour],
    FORMAT(date, 'mm') AS [min],
    CASE
        WHEN DATEPART(HOUR, date) < 12 THEN 'AM'
        ELSE 'PM'
    END AS sg,
    date
FROM (
    SELECT PickupDateTime AS date FROM [dbo].[STG_TRIPS]
    UNION
    SELECT DropoffDateTime AS date FROM [dbo].[STG_TRIPS]
) AS combined_dates;

GO

-- TR_DIM_LICENSE

INSERT INTO [dbo].[DIM_LICENSE] (
    licenseID, license_num, entity_name, telephone, SHL_endorsed, building,

```

```

        street, city, state, postcode, type_base, [date], hora, location
    )

SELECT DISTINCT
    LicenseID, LicenseNum, EntityName, Telephone, SHL_endorsed, Building,
    Street, City, State, Postcode, Type_Base, [Date], Hora, Location
FROM
    [dbo].[STG_LICENCES];

GO

-- 4. TRANSFORMACIONES PARA TABLAS DE HECHOS

-- TR_FACT_NYTAXI_TRIP

INSERT INTO [dbo].[FACT_NYTAXI_TRIP] (
    nytaxi_trip_id, vendorID, pickup_datetimeID, dropoff_datetimeID,
    rateID, PULocationID, DOLocationID, paymentID,
    IsStoredAndForwarded, extra, mta_tax, tip_amount, tolls_amount,
    improvement_surcharge, congestion_surcharge, airport_free,
    taxi_trip, passenger, distance, duration, fare_amount, total_amount
)

SELECT
    s.TripID,
    s.VendorID,
    t_pick.timeID,
    t_drop.timeID,
    s.RateID,
    s.PULocationID,
    s.DOLocationID,
    s.PaymentTypeID,
    s.IsStoredAndForwarded,
    s.Extra,
    s.MTATax,
    s.TipAmount,
    s.TollsAmount,
    s.ImprovementSurcharge,
    s.CongestionSurcharge,
    s.AirportFee,
    s.TaxiTrip,
    s.PassengerCount,
    s.TripDistance,
    s.Duration,
    s.FareAmount,

```

```

        s.TotalAmount
FROM
    [dbo].[STG_TRIPS] s
LEFT JOIN
    [dbo].[DIM_TIME] t_pick ON t_pick.[date] = s.PickupDateTime
LEFT JOIN
    [dbo].[DIM_TIME] t_drop ON t_drop.[date] = s.DropoffDateTime;

GO

-- TR_FACT_FHV_TRIP
INSERT INTO [dbo].[FACT_FHV_TRIP] (
    fhv_trip_id, licenseID, pickup_datetimeID, dropoff_datetimeID,
    PULocationID, DOLocationID, SR_flag, Affiliated_num,
    fhv_trip, duration
)
SELECT
    s.TripID AS fhv_trip_id,
    l.licenseID,
    t_pick.timeID,
    t_drop.timeID,
    s.PULocationID,
    s.DOLocationID,
    s.SR_flag,
    s.Affiliated_num,
    s.fhv_trip,
    s.Duration
FROM
    [dbo].[STG_TRIPS] s
LEFT JOIN
    [dbo].[DIM_TIME] t_pick ON t_pick.[date] = s.PickupDateTime
LEFT JOIN
    [dbo].[DIM_TIME] t_drop ON t_drop.[date] = s.DropoffDateTime
LEFT JOIN
    [dbo].[DIM_LICENSE] l ON l.license_num = s.LicenseNum; -- Corrección del
JOIN
GO

```

Validaciones Realizadas

Durante el desarrollo, se revisaron los nombres de las columnas y las relaciones para garantizar la integridad de los datos y evitar inconsistencias. Las columnas adicionales y ajustes realizados están respaldados por el análisis detallado del documento *Solución PR1.pdf*.

En resumen, este script refleja la aplicación práctica de las especificaciones teóricas y garantiza un flujo ETL sólido y eficiente.

Verificación y Validación Final

Después de ejecutar el script completo, debería verificar que los datos se hayan cargado correctamente en todas las tablas dimensionales y de hechos.

```
-- Verificar registros en DIM_LOCATION
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_LOCATION];
-- Verificar registros en DIM_VENDOR
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_VENDOR];
-- Verificar registros en DIM_PAYMENT
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_PAYMENT];
-- Verificar registros en DIM_RATE
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_RATE];
-- Verificar registros en DIM_TIME
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_TIME];
-- Verificar registros en DIM_LICENSE
SELECT COUNT(*) AS TotalRecords FROM [dbo].[DIM_LICENSE];
-- Verificar registros en FACT_NYTAXI_TRIP
SELECT COUNT(*) AS TotalRecords FROM [dbo].[FACT_NYTAXI_TRIP];
-- Verificar registros en FACT_FHV_TRIP
SELECT COUNT(*) AS TotalRecords FROM [dbo].[FACT_FHV_TRIP];
```

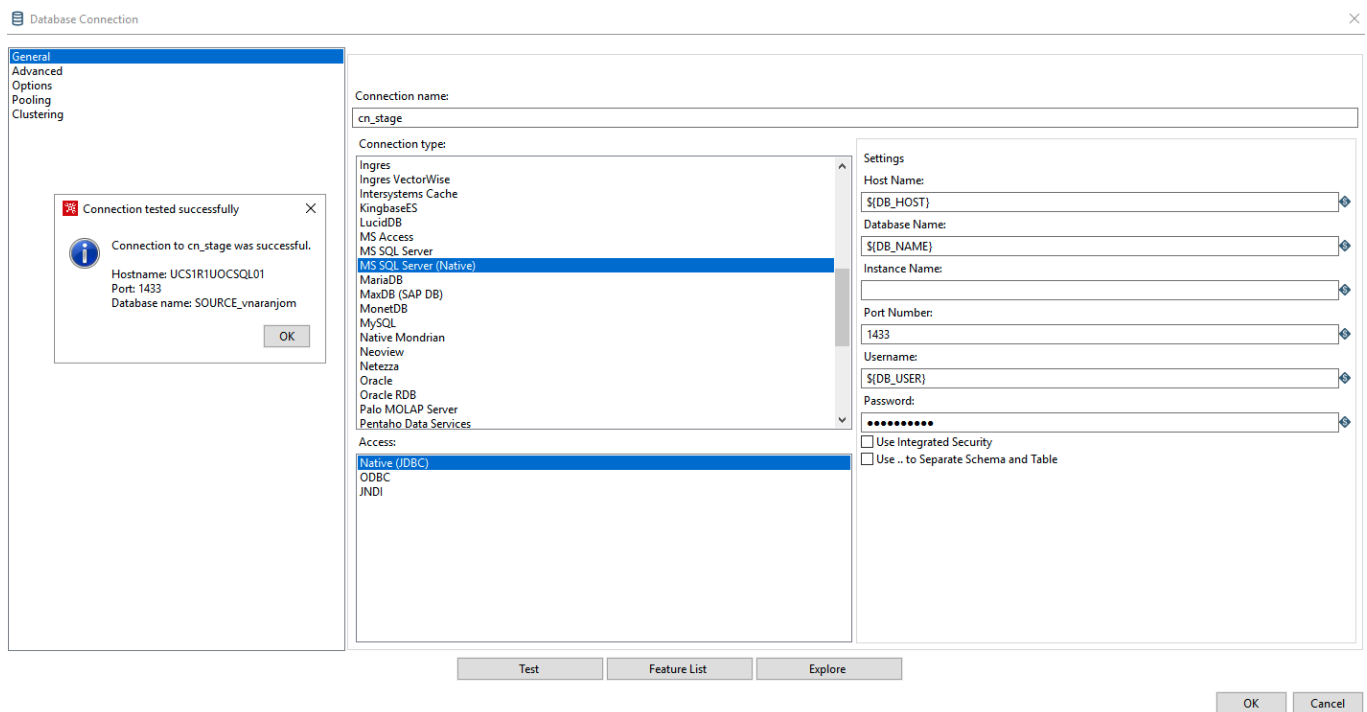
Establecer el entorno

Para ahorrarme el paso del driver he aplicado la siguiente solución:

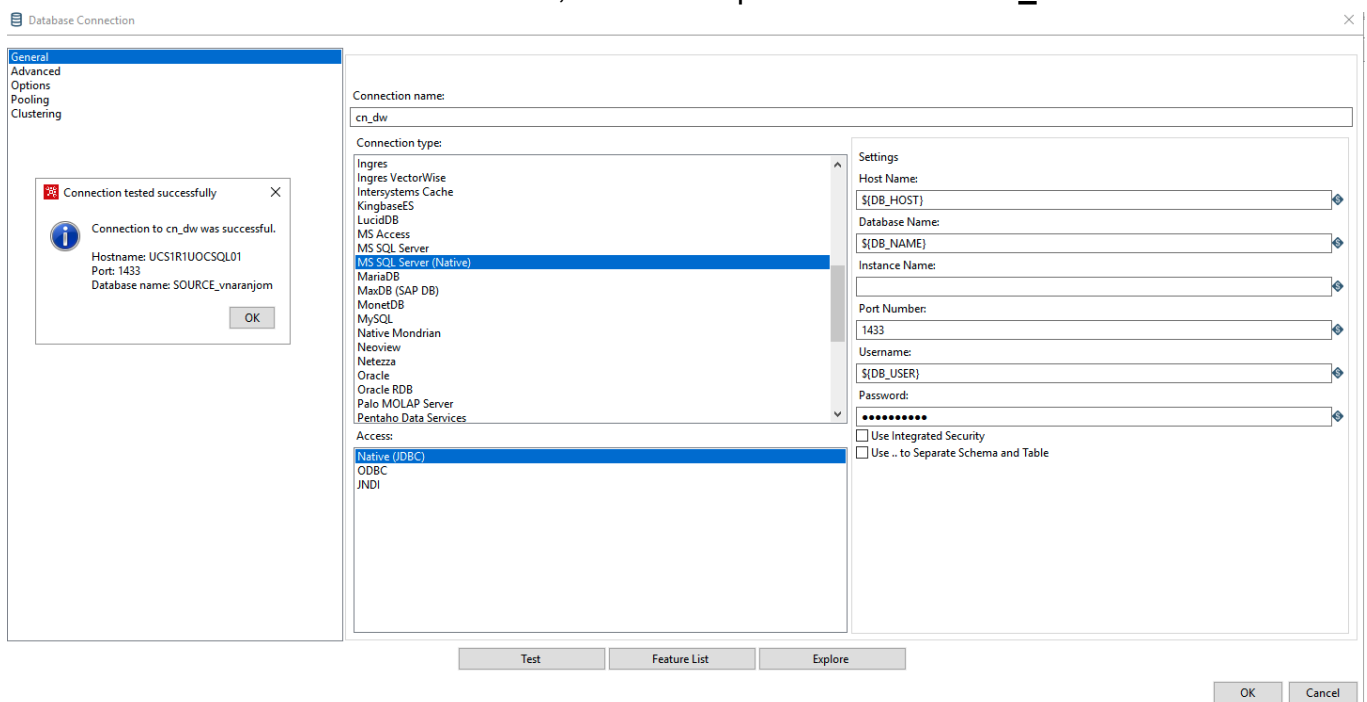
```
# Ruta a las fuentes de datos
DIR_ENT=F:\fuentes

DB_HOST=UCS1R1U0CSQL01
DB_PORT=1433
DB_NAME=GOG
DB_USER=STUDENT_vnaranjom
```

Connection». En la creación de la conexión al «STAGE», el nombre que se les asignará es **cn_stage**:



En la creación de la conexión al «DW», el nombre que se le dará es **cn_dw**:



Uso de Variables de Entorno vs Cadena de Conexión Completa

Ventajas del uso de variables de entorno

1. Portabilidad:

- Definir valores como `DB_HOST`, `DB_PORT`, `DB_NAME`, `DB_USER`, y `DB_PASS` me permite configurar diferentes entornos (desarrollo, producción, staging) sin modificar

directamente mis transformaciones o trabajos. Solo cambio el archivo `Kettle.properties`, y listo.

2. Flexibilidad:

- Si tengo que conectarme a un servidor diferente o usar credenciales distintas, no necesito tocar la configuración dentro de Pentaho. Solo edito el archivo de variables de entorno, y todos los procesos automáticamente usarán los nuevos valores.

3. Simplicidad sin dependencias externas:

- Al no usar cadenas de conexión completas como `jdbc:sqlserver://<host>:<port>;databaseName=<name>;user=<user>;password=<password>`, evito depender de drivers personalizados que no puedo instalar porque no soy administrador del sistema. Esto hace que mi configuración sea más sencilla y menos propensa a errores.

4. Claridad en la diferenciación de conexiones:

- Aunque ambas conexiones (`cn_stage` y `cn_dw`) apuntan físicamente al mismo esquema en la base de datos, usar variables separadas para definirlos en Pentaho hace que su propósito quede claramente diferenciado. Por ejemplo:
 - `cn_stage` para el área intermedia.
 - `cn_dw` para la base de datos multidimensional.

5. Seguridad:

- Las credenciales y la información sensible no están expuestas directamente en las transformaciones o trabajos. Quedan centralizadas y protegidas en el archivo `Kettle.properties`, lo que minimiza el riesgo de filtraciones.


Configuración actual: Resultado

Gracias a las variables de entorno:

- He podido definir claramente dos conexiones lógicas (`cn_stage` y `cn_dw`), ambas apuntando al mismo esquema físico, pero con usos diferenciados en mi proceso ETL.
- No necesito instalar drivers adicionales, lo que es ideal considerando las restricciones de mi entorno.
- Mi configuración es más clara, portable, y fácil de mantener.

Transformaciones para STG_TAXI_ZONES

Tabla de entrada

 Help

Get Fields

Cancel

Tabla de salida

Table output

Step name: STG_TAXI_ZONES

Connection: cn_stage [Edit...] [New...] [Wizard...]

Target schema: dbo [Browse...]

Target table: STG_TAXI_ZONES [Browse...]

Commit size: 1000

Truncate table: ☒

Ignore insert errors: ☐

Specify database fields: ☒

Main options | Database fields

Partition data over tables: ☐
Partitioning field: []

Partition data per month: ☒
Partition data per day: ☐

Use batch update for inserts: ☒


Is the name of the table defined in a field? ☐
Field that contains name of table: []

Store the tablename field: ☒


Return auto-generated key: ☐
Name of auto-generated key field: []

[?] Help [OK] [Cancel] [SQL]

Conexión de las tablas



Eliminar filas con "N/A"

 Filter rows

—

□

×

Step name

Filter rows

Send 'true' data to step:

STG_TAXI_ZONES

▼

Send 'false' data to step:

▼

The condition:

NOT

service_zone

=

N/A

(String)

+

?

 Help

OK

Cancel

Compruebo en la base de datos que todo esta bien.

```

/***** Script for SelectTopNRows command from SSMS *****/

```

```

SELECT *

```

```

FROM [SOURCE_vnaranjom].[dbo].[STG_TAXI_ZONES]

```

100 %



Results

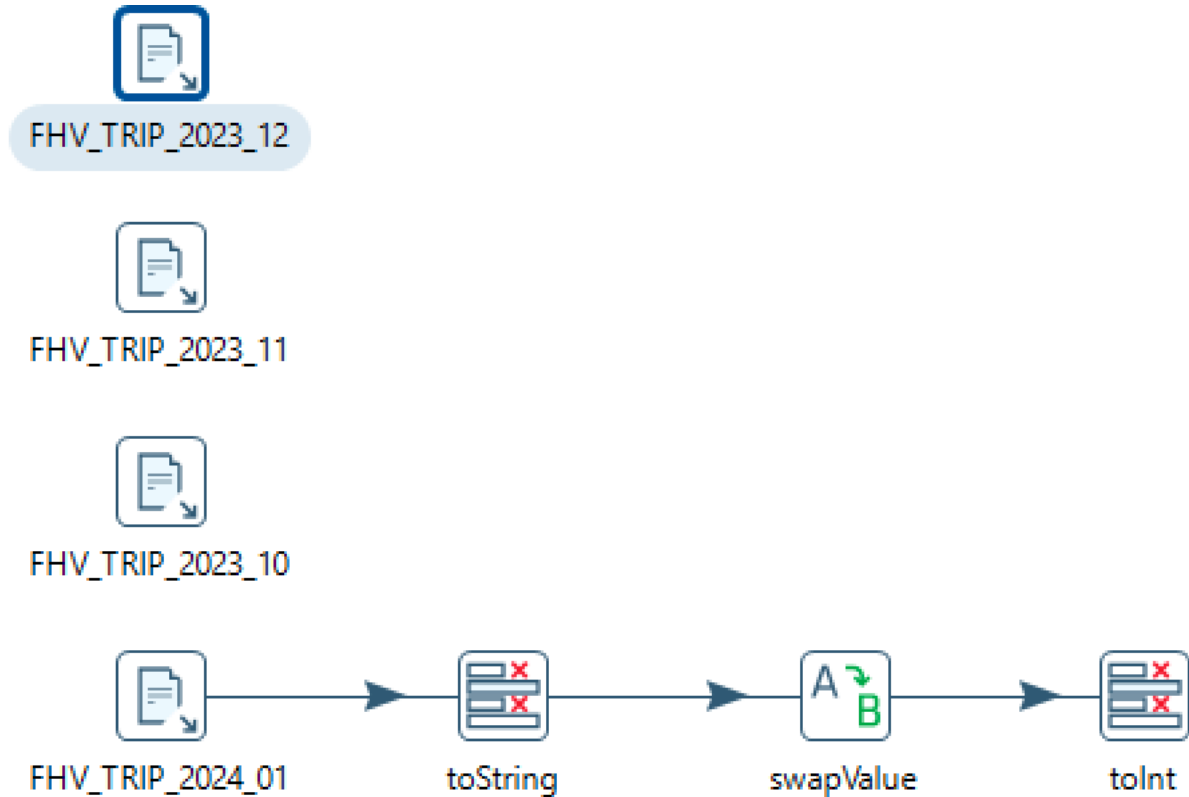


Messages

	LocationID	Borough	Zone	Service_zone
236	236	Manhattan	Upper East Side North	Yellow Zone
237	237	Manhattan	Upper East Side South	Yellow Zone
238	238	Manhattan	Upper West Side North	Yellow Zone
239	239	Manhattan	Upper West Side South	Yellow Zone
240	240	Bronx	Van Cortlandt Park	Boro Zone
241	241	Bronx	Van Cortlandt Village	Boro Zone
242	242	Bronx	Van Nest/Morris Park	Boro Zone
243	243	Manhattan	Washington Heights North	Boro Zone
244	244	Manhattan	Washington Heights South	Boro Zone
245	245	Staten Island	West Brighton	Boro Zone
246	246	Manhattan	West Chelsea/Hudson Yards	Yellow Zone
247	247	Bronx	West Concourse	Boro Zone
248	248	Bronx	West Farms/Bronx River	Boro Zone
249	249	Manhattan	West Village	Yellow Zone
250	250	Bronx	Westchester Village/Unionport	Boro Zone
251	251	Staten Island	Westerleigh	Boro Zone
252	252	Queens	Whitestone	Boro Zone
253	253	Queens	Wilets Point	Boro Zone
254	254	Bronx	Williamsbridge/Olinville	Boro Zone
255	255	Brooklyn	Williamsburg (North Side)	Boro Zone
256	256	Brooklyn	Williamsburg (South Side)	Boro Zone
257	257	Brooklyn	Windsor Terrace	Boro Zone
258	258	Queens	Woodhaven	Boro Zone
259	259	Bronx	Woodlawn/Wakefield	Boro Zone
260	260	Queens	Woodside	Boro Zone
261	261	Manhattan	World Trade Center	Yellow Zone
262	262	Manhattan	Yorkville East	Yellow Zone
263	263	Manhattan	Yorkville West	Yellow Zone

Transformaciones para STG_TRIPS

Para resolver este problema, lo abordé de la siguiente manera:



1. Identificación del problema:

- Durante la integración de los datos de los diferentes archivos `FHV_TRIP`, noté que uno de ellos (`FHV_TRIP_2024_01`) tenía el campo `PULocationID` definido como un **boolean**, mientras que en el resto de los archivos y en la tabla destino este campo debía ser un **integer**.
- Esto generaba un conflicto al intentar unificar los flujos de datos debido a la inconsistencia en los tipos de datos.

2. Solución paso a paso:

- **Convertí el campo `PULocationID` a un tipo de texto (String):** Usé un paso de **Select Values** para cambiar temporalmente el tipo de dato a `String`. Esto me permitió manejar los valores `N` y `null` sin errores de tipo.
- **Reemplacé los valores booleanos por enteros:** Implementé un paso **Value Mapper** para asignar:
 - `N` \rightarrow `0`
 - `null` (o cualquier valor no coincidente) \rightarrow `-1` (indicando datos faltantes).
- **Convertí el campo nuevamente a un tipo Integer:** Utilicé otro paso **Select Values** para convertir el campo de texto resultante de `Value Mapper` a un entero

(Integer), cumpliendo así con el esquema de la tabla destino.

3. Validación:

- Verifiqué el flujo de datos previsualizando después de cada paso para asegurarme de que las transformaciones se aplicaran correctamente.
- Finalmente, confirmé que el campo `PULocationID` estaba unificado y en el formato correcto en todos los flujos.

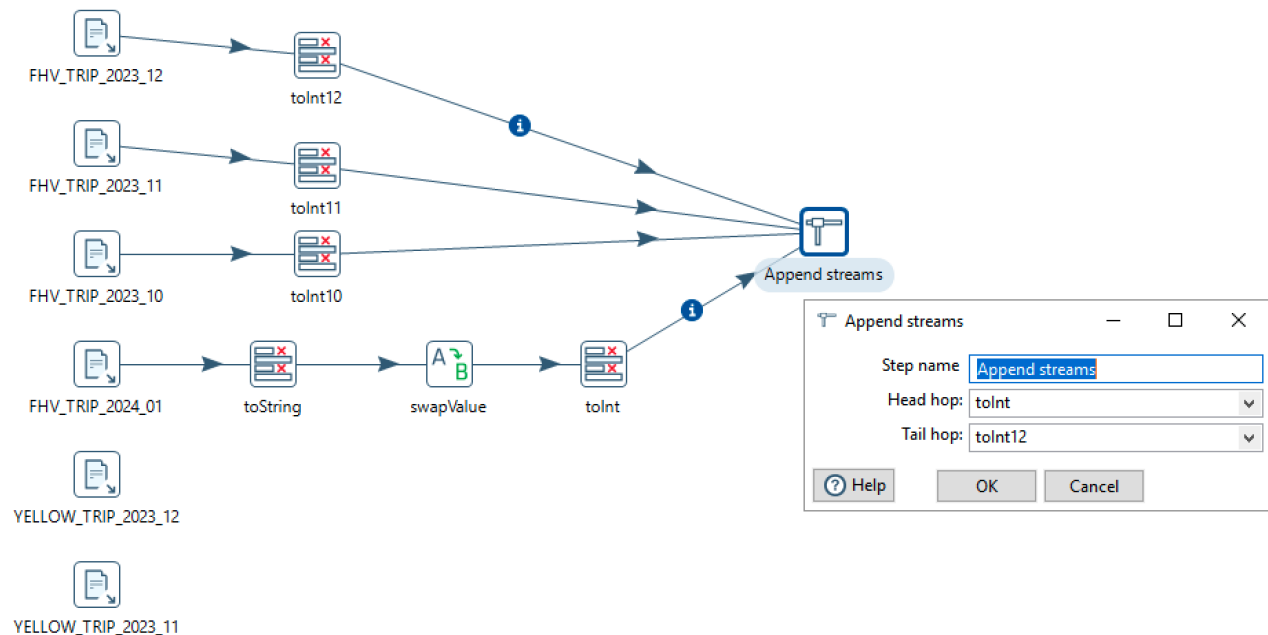
4. Conclusión:

- Este enfoque resolvió el conflicto entre los tipos de datos, lo que permitió combinar los datos de todos los archivos sin errores y cargar los resultados en la tabla destino conforme al esquema definido.

Rows of step: toInt (1000 rows)

#	dispatching_base_num	pickup_datetime	dropOff_datetime	PULocationID	DOLocationID	SR_Flag	Affiliated_base_number
1	B00053	2024-01-01 00:15:00	2024-01-01 02:13:00	-1,0	<null>	<null>	B00014
2	B00111	2024-01-01 00:30:00	2024-01-01 02:37:00	-1,0	<null>	<null>	B00111
3	B00112	2024-01-01 00:27:24	2024-01-01 01:12:05	-1,0	14	<null>	B00112
4	B00112	2024-01-01 00:10:09	2024-01-01 00:25:39	-1,0	133	<null>	B00112
5	B00112	2024-01-01 00:57:07	2024-01-01 01:05:04	-1,0	14	<null>	B00112
6	B00112	2024-01-01 00:50:18	2024-01-01 01:29:31	-1,0	91	<null>	B00112
7	B00112	2024-01-01 00:11:16	2024-01-01 00:11:21	-1,0	14	<null>	B00112
8	B00112	2024-01-01 00:38:29	2024-01-01 00:47:47	-1,0	14	<null>	B00112
9	B00112	2024-01-01 00:51:36	2024-01-01 00:58:14	-1,0	14	<null>	B00112
10	B00112	2024-01-01 00:36:54	2024-01-01 00:37:10	-1,0	67	<null>	B00112
11	B00149	2024-01-01 00:44:31	2024-01-01 00:51:02	-1,0	72	<null>	B03011
12	B00149	2024-01-01 00:58:35	2024-01-01 01:05:52	-1,0	72	<null>	B03011
13	B00149	2024-01-01 00:34:12	2024-01-01 00:57:19	-1,0	61	<null>	B03404
14	B00149	2024-01-01 00:12:29	2024-01-01 00:32:12	-1,0	71	<null>	B03404
15	B00149	2024-01-01 00:42:37	2024-01-01 00:56:49	-1,0	61	<null>	B03404
16	B00149	2024-01-01 00:34:48	2024-01-01 00:45:35	-1,0	61	<null>	B02932

Paso todos la integer de longitud 15 y precisión 0 ya que es el mismo tipo de dato en Yellow_Trip_Data.



Unir los cuatro datasets.

El paso "**AddNewConstants**" es fundamental para asegurar que los datos de ambos flujos (FHV y YELLOW) tengan una estructura homogénea, lo cual es un requisito indispensable para realizar correctamente el paso de **Append Streams**.

Razones por las que este paso es necesario:

1. Unificación de Estructura:

Los datos provenientes de **FHV_TRIP** no incluyen todos los campos presentes en **YELLOW_TRIP**. Este paso añade dichos campos faltantes con valores por defecto (`null` en este caso).

2. Consistencia en Tipos de Datos:

Al agregar estos campos, se define explícitamente su tipo de dato, longitud y precisión, asegurando que coincidan con los campos existentes en **YELLOW_TRIP**. Esto elimina errores de incompatibilidad al intentar unir los flujos.

3. Estandarización de Procesos Posteriores:

Asegura que cualquier transformación o análisis posterior pueda tratar los datos de ambos flujos de manera uniforme sin necesitar verificaciones adicionales o transformaciones extra.

4. Evitar Errores en la Unión de Flujos:

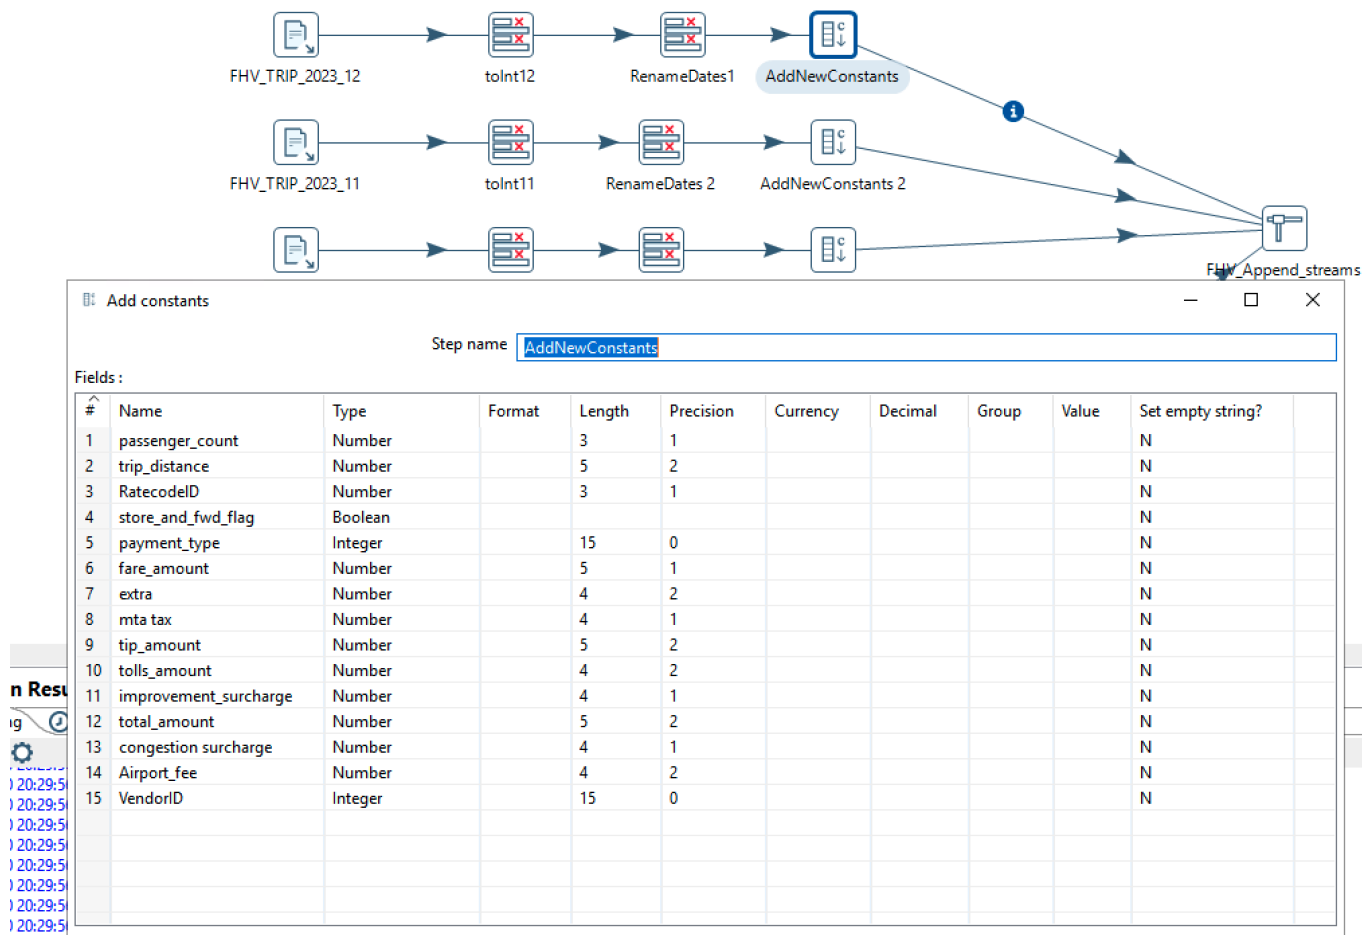
Pentaho requiere que los flujos a unir tengan los mismos campos (nombre, tipo y formato). Sin este paso, el proceso de unión arrojaría errores, ya que faltarían campos clave.

5. Flexibilidad para Manejar Valores Vacíos:

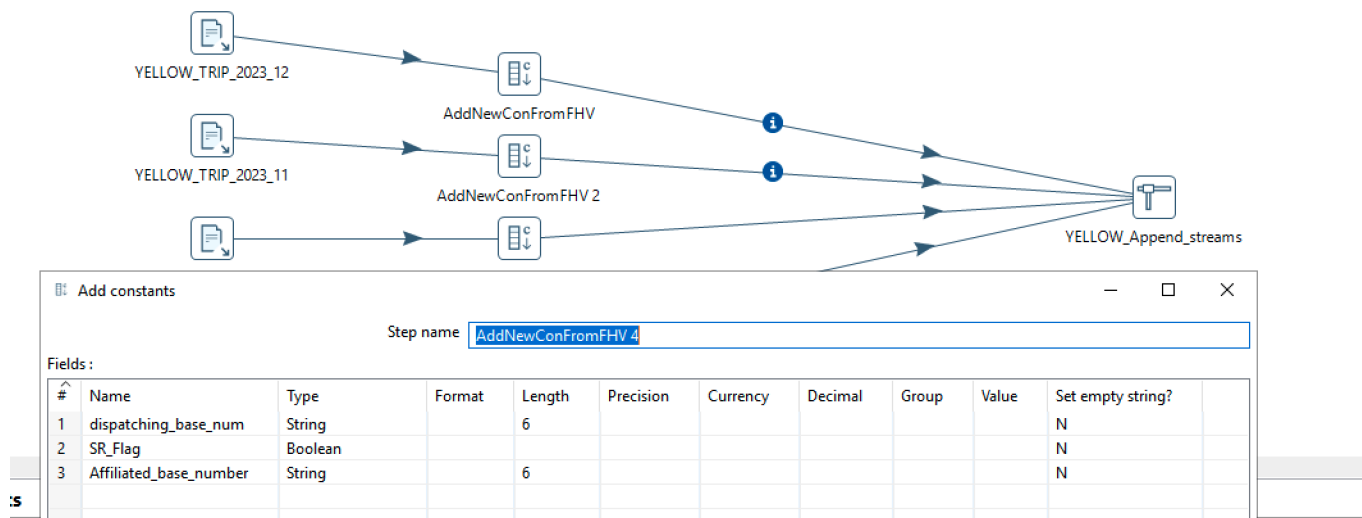
Al establecer valores por defecto como `null`, se preserva la capacidad de diferenciar datos ausentes de valores explícitos (como `0`), lo que es útil para análisis más precisos.

En resumen, este paso es crucial para garantizar la integridad y la compatibilidad de los datos al consolidar los flujos en una estructura única y manejable.

Faltantes en FHV_TRIP_DATA (presentes en YELLOW_TRIP_DATA)



Faltantes en YELLOW_TRIP_DATA (presentes en FHV_TRIP_DATA)



En la siguiente imagen se visualiza el flujo de preparación y unificación de datos provenientes de diferentes fuentes relacionadas con los registros de viajes FHV (For-Hire Vehicles) y Yellow Taxi, con el objetivo final de insertarlos en la tabla **STG_TRIPS**. El proceso fue llevado a cabo de la siguiente manera:

1. Procesamiento de FHV_TRIP:

- Cada archivo correspondiente a los diferentes periodos de FHV (FHV_TRIP_2023_12 , FHV_TRIP_2023_11 , etc.) fue procesado individualmente.
- Se normalizaron los tipos de datos mediante pasos como `toInt` y `toString` para garantizar que todas las columnas tuvieran el formato correcto.
- Se agregaron columnas constantes necesarias (`AddNewConstants`) que no estaban presentes en los datos originales de FHV para que coincidan con el esquema de Yellow Taxi.
- Finalmente, los datos fueron ordenados (`Sort`) para mantener consistencia en el flujo.

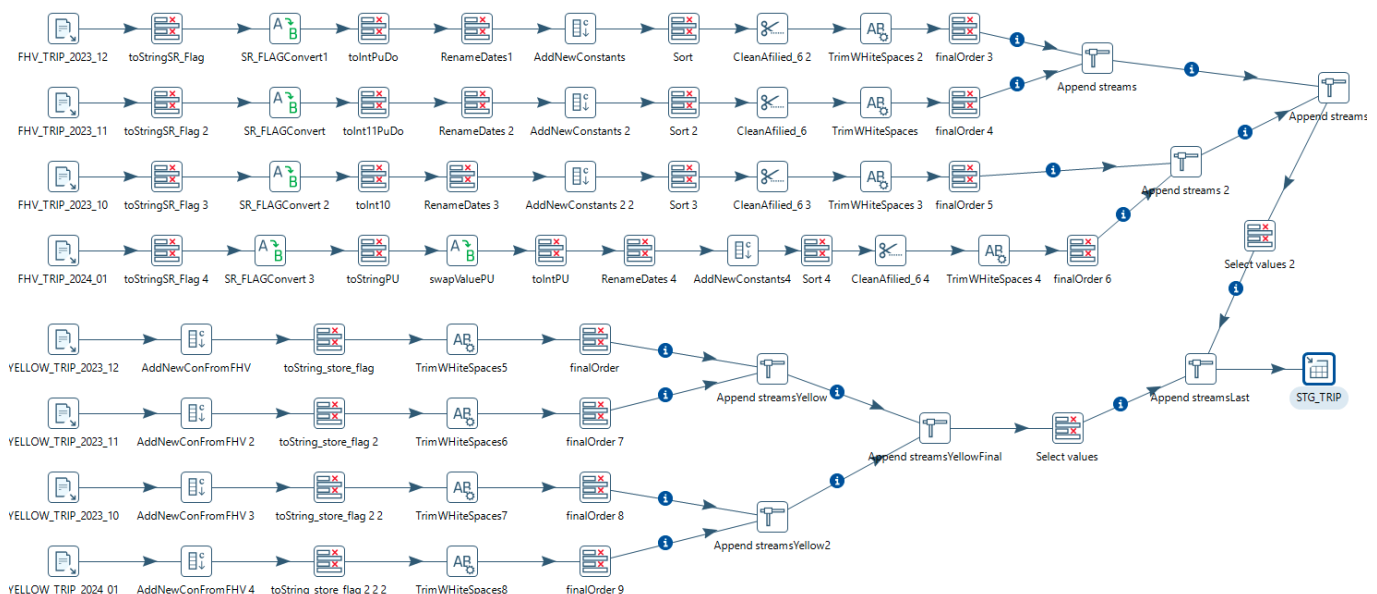
2. Procesamiento de YELLOW_TRIP:

- De manera similar, los datos de Yellow Taxi de diferentes periodos (YELLOW_TRIP_2023_12 , YELLOW_TRIP_2023_11 , etc.) también pasaron por un proceso de enriquecimiento mediante el paso `AddNewConFromFHV` , donde se agregaron columnas para alinear su estructura con los datos de FHV.

3. Unificación de Datos:

- Se utilizaron varios pasos de `Append streams` para combinar los datos procesados de FHV y Yellow Taxi.
- Este proceso asegura que todas las columnas tengan el mismo orden, tipo y estructura antes de unificar los flujos.
- Finalmente, el último paso de unificación (`Append streams 2`) generó un flujo consolidado listo para ser cargado en **STG_TRIPS**.

En resumen, este flujo de trabajo asegura que los datos de ambas fuentes estén alineados tanto en estructura como en formato, lo que permite su integración y posterior uso en el almacén de datos o procesos analíticos.



Configuro la tabla de salida:

Table output

Step name

Connection

Target schema

Target table

Commit size

Truncate table ☒

Ignore insert errors ☐

Specify database fields ☒

Main options Database fields

Partition data over tables ☐

Partitioning field

Partition data per month ☒

Partition data per day ☐

Use batch update for inserts ☒

Is the name of the table defined in a field? ☐

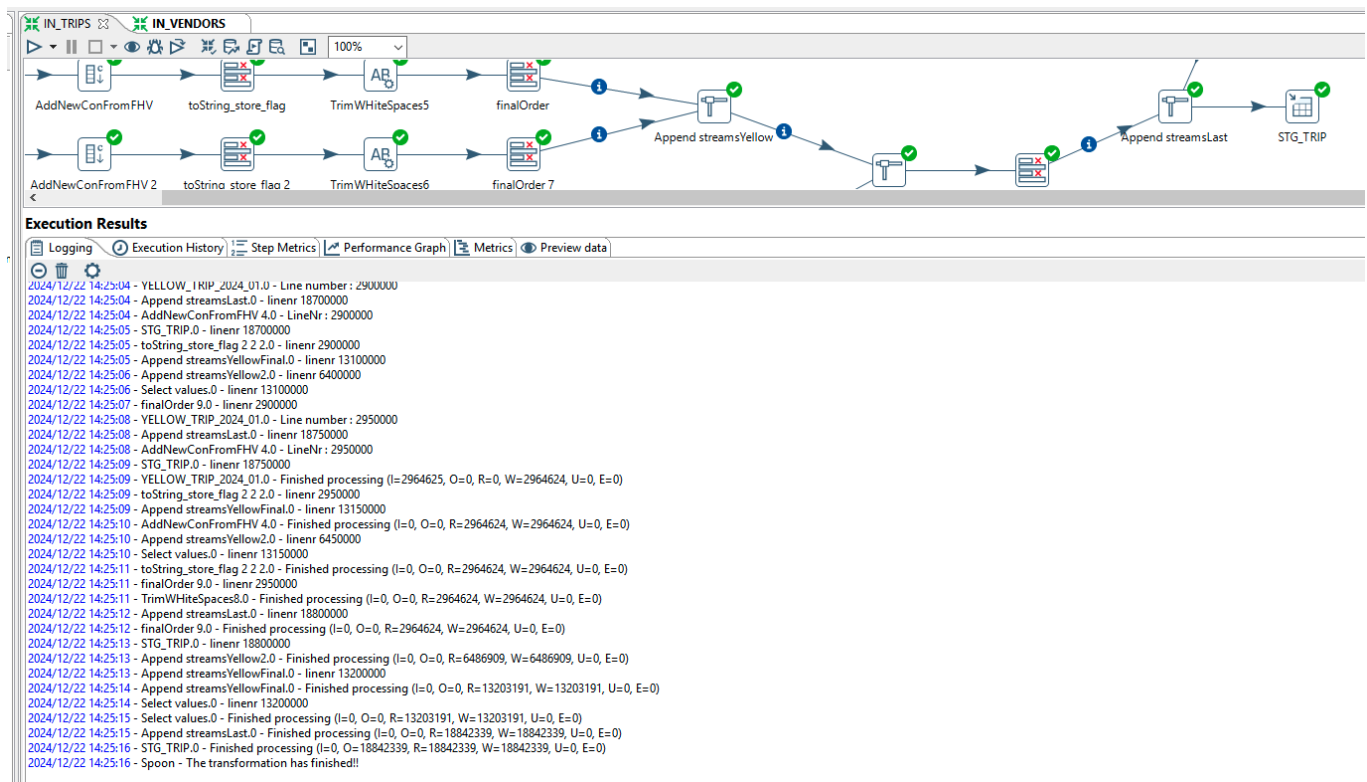
Field that contains name of table:

Store the tablename field ☒

Return auto-generated key ☐

Name of auto-generated key field

Las transformaciones se han realizado correctamente:



Comprobación en la base de datos:

```

Script for Selection of knowns command from SSMS
SELECT TOP (1000) [VendorID]
, [tpep_pickup_datetime]
, [tpep_dropoff_datetime]
, [passenger_count]
, [trip_distance]
, [RatecodeID]
, [store_and_fwd_flag]
, [PULocationID]
, [DOLocationID]
, [payment_type]
, [fare_amount]
, [extra]
, [mta_tax]
, [tip_amount]
, [tolls_amount]
, [improvement_surcharge]
, [total_amount]
, [congestion_surcharge]
, [Airport_fee]
, [dispatching_base_num]
, [SR_Flag]

```

	VendorID	tpep_pickup_datetime	tpep_dropoff_datetime	passenger_count	trip_distance	RatecodeID	store_and_fwd_flag	PULocationID	DOLocationID	payment_type	fare_amount
1	NULL	2023-12-01 10:22:09.000	2023-12-01 10:38:47.000	NULL	NULL	NULL	NULL	NULL	89	NULL	NULL
2	NULL	2023-12-01 10:14:44.000	2023-12-01 10:19:55.000	NULL	NULL	NULL	NULL	NULL	26	NULL	NULL
3	NULL	2023-12-01 10:30:32.000	2023-12-01 10:44:21.000	NULL	NULL	NULL	NULL	NULL	26	NULL	NULL
4	NULL	2023-12-01 10:52:26.000	2023-12-01 11:07:21.000	NULL	NULL	NULL	NULL	NULL	227	NULL	NULL
5	NULL	2023-12-01 10:06:32.000	2023-12-01 10:11:15.000	NULL	NULL	NULL	NULL	NULL	26	NULL	NULL
6	NULL	2023-12-01 10:27:59.000	2023-12-01 10:32:24.000	NULL	NULL	NULL	NULL	NULL	26	NULL	NULL
7	NULL	2023-12-01 10:40:29.000	2023-12-01 10:45:12.000	NULL	NULL	NULL	NULL	NULL	26	NULL	NULL

Transformaciones para STG_VENDORS

Código para transformar de tsv a csv

```

import pandas as pd
# Leer el archivo TSV
df = pd.read_csv('CURRENT_BASES.tsv', sep='\t')

```

```
# Guardar como CSV
df.to_csv('CURRENT_BASES.csv', index=False)
```

Código para eliminar el duplicado:

```
import pandas as pd

# Cargar el archivo CSV
file_path = "CURRENT_BASES.csv" # Ruta del archivo
data = pd.read_csv(file_path)

# Contar el número de registros antes de la eliminación
initial_count = data.shape[0]

# Eliminar duplicados del número de licencia B02920, manteniendo solo la
primera aparición
data = data[~((data["License Number"] == "B02920") &
(data.duplicated(subset=["License Number"], keep="first")))]

# Contar el número de registros después de la eliminación
final_count = data.shape[0]

# Mostrar los resultados
print(f"Registros antes de la eliminación: {initial_count}")
print(f"Registros después de la eliminación: {final_count}")

# Guardar el archivo actualizado
data.to_csv("CURRENT_BASES_UPDATED.csv", index=False)
```

```
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes % python tsvTocsv.py
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes % python deleteTwin.py
Registros antes de la eliminación: 853
Registros después de la eliminación: 852
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes %
```


He decidido eliminar el dato duplicado en la columna **LicenseNumber** porque este campo debe ser único para garantizar la integridad de los datos. La duplicidad identificada en el registro con el valor **B02920** representaba una inconsistencia en la fuente de datos, ya que se trata de una clave primaria que, por definición, no puede repetirse en el sistema.

Eliminé uno de los registros duplicados considerando que la localización no influye en el contexto del análisis o la finalidad de este conjunto de datos. Además, mantener la duplicidad podría generar problemas en futuros procesos de integración, consultas o reportes, como errores de referencias cruzadas o cálculos incorrectos basados en datos duplicados.

Por estas razones, opté por conservar un único registro y eliminar el duplicado, asegurando así la coherencia y fiabilidad de los datos para su procesamiento posterior.

He modificado los encabezados para eliminar los espacios entre los nombres y evitar problemas:

```
LicenseNumber,EntityName,Telephone Number,SHL
Endorsed,Building,Street,City,State,Postcode,TypeOfBase,Latitude,Longitude,D
ate,Time,Location
```



```
graph LR; A[CSV file input] --> B[TrimWhiteSpaces]; B --> C[STG_VENDORS];
```

Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

2024/12/22 15:37:36 - Spoon - Running transformation using the Kettle execution engine

2024/12/22 15:37:36 - Spoon - Transformation opened.

2024/12/22 15:37:36 - Spoon - Launching transformation [IN_VENDORS]...

2024/12/22 15:37:36 - Spoon - Started the transformation execution.

2024/12/22 15:37:36 - IN_VENDORS - Dispatching started for transformation [IN_VENDORS]

2024/12/22 15:37:37 - STG_VENDORS.0 - Connected to database [cn_stage] (commit=1000)

2024/12/22 15:37:37 - CSV file input.0 - Header row skipped in file 'F:\Vini\ Fuentes\CURRENT_BASES_UPDATED_PostCodeSpaces.csv'

2024/12/22 15:37:37 - CSV file input.0 - Finished processing (I=853, O=0, R=0, W=852, U=0, E=0)

2024/12/22 15:37:37 - TrimWhiteSpaces.0 - Finished processing (I=0, O=0, R=852, W=852, U=0, E=0)

2024/12/22 15:37:37 - STG_VENDORS.0 - Finished processing (I=0, O=852, R=852, W=852, U=0, E=0)

2024/12/22 15:37:37 - Spoon - The transformation has finished!!

Comprobación de las transformaciones en la base de datos:

SQLQuery2.sql - U...NT_vnaranjom (69) SQLQuery1Delete...T_vnaranjom (151)* SQLQuery1.sql - UC...T_vnaranjom (139)*

```
/****** Script for SelectTopNRows command from SSMS ******/
SELECT TOP (1000) [LicenseNumber]
,[EntityName]
,[TelephoneNumber]
,[Building]
,[Street]
,[City]
,[State]
,[Postcode]
,[TypeOfBase]
,[Latitude]
,[Longitude]
,[Date]
,[Time]
FROM [SOURCE_vnaranjom].[dbo].[STG_VENDORS]
```

100 %

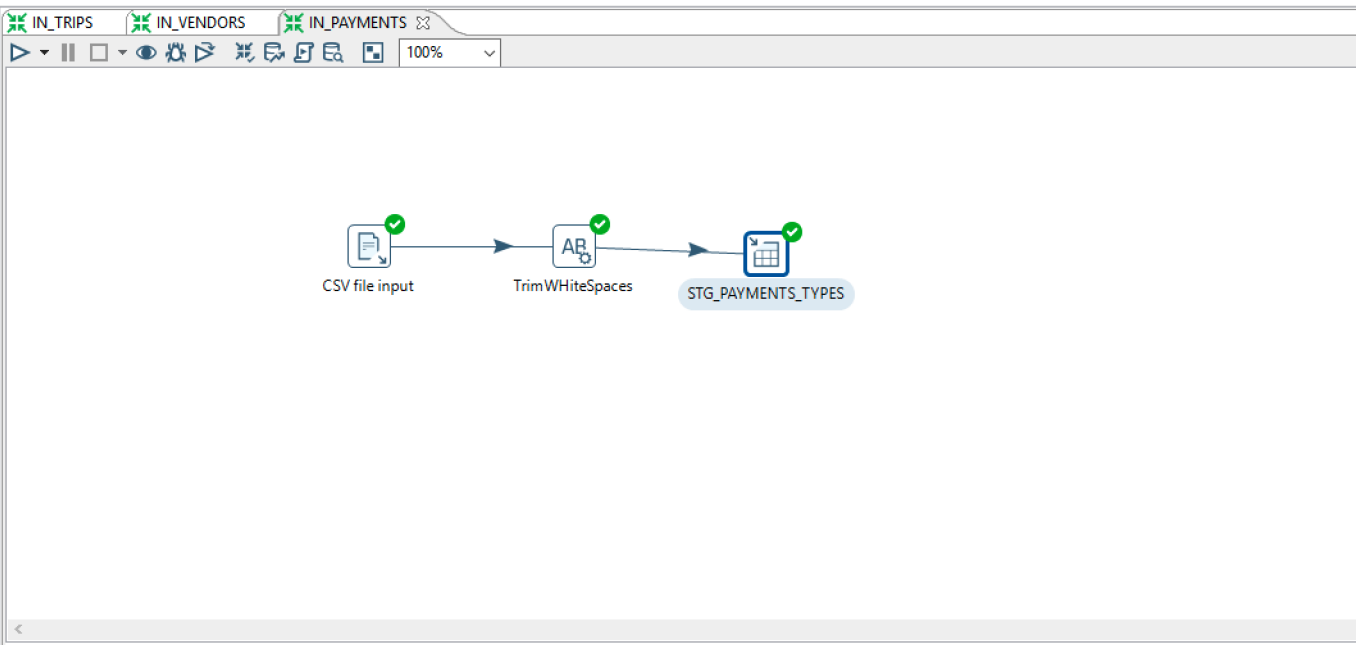
Results Messages

	LicenseNumber	EntityName	TelephoneNumber	Building	Street	City	State	Postcode	TypeOfBase	Latitude	Longitude	Date	Time
1	B00001	LONDON TOWNCARS INC	2129889700	40-14	23 STREET	L.I.C	NY	11101	LUXURY/LIMOUSINE	40,754052	-73,940055	2024-03-15	18:00:13
2	B00008	T-D MAINTENANCE CORP	7184561111	127-01	METROPOLITAN AVENUE	KEW GARDENS	NY	11415	LIVERY BASE	40,70681	-73,87768	2024-03-15	18:00:13
3	B00009	T-D MAINTENANCE	7184561111	127-01	METROPOLITAN AVENUE	KEW GARDENS	NY	11415	LIVERY BASE	40,70681	-73,877681	2024-03-15	18:00:13
4	B00013	LOVE CORPORATE CAR INC	7186333333	1751	BATH AVENUE	BROOKLYN	NY	11214	BLACK CAR BASE	40,638477	-73,983333	2024-03-15	18:00:13
5	B00014	NY ONE CORP CAR INC	7184387474	1751	BATH AVENUE	BROOKLYN	NY	11214	BLACK CAR BASE	40,638477	-73,983333	2024-03-15	18:00:13
6	B00053	CHARGE AND RIDE INC	7183921824	41-24	38 STREET	LIC	NY	11101	BLACK CAR BASE	40,745304	-73,95305	2024-03-15	18:00:13
7	B00054	128 BLUE BIRD TRANSPORT INC.	7185297748	111-05	128 STREET	OZONE PARK	NY	11420	LIVERY BASE	40,683921	-73,813971	2024-03-15	18:00:13
8	B00056	TRANSIT PRIVATE CAR SERVICE INC.	7186494100	1407	ROCKAWAY PARKWAY	BROOKLYN	NY	11236	LIVERY BASE	40,645455	-73,902663	2024-03-15	18:00:13
9	B00078	R & R ROAD LIMO SVCE INC	7185858500	865	EAST 138 STREET	BRONX	NY	10454	LUXURY/LIMOUSINE	40,803251	-73,90843	2024-03-15	18:00:13
10	B00084	AUTOMOTIVE SVC SYSTEM INC	2129666400	50-21	49 STREET	WOODSIDE	NY	11377	LUXURY/LIMOUSINE	40,736268	-73,916901	2024-03-15	18:00:13
11	B00095	LIBERTY CAR SERVICE INC.	7183666666	689	SENECA AVENUE	RIDGEWOOD	NY	11385	LIVERY BASE	40,70305	-73,907668	2024-03-15	18:00:13
12	B00111	SKYLINE CREDIT RIDE INC	7184828585	37-02	48TH AVENUE	L.I.C	NY	11101	BLACK CAR BASE	40,735627	-73,93612	2024-03-15	18:00:13
13	B00112	AYY&M TRANSPORTATION, LLC	7186802500	9425	5 AVENUE	BROOKLYN	NY	11209	LIVERY BASE	40,615867	-74,030649	2024-03-15	18:00:13
14	B00149	RAINBOW RAD DISP INC	7184984444	1304	UTICA AVENUE	BROOKLYN	NY	11203	LIVERY BASE	40,640752	-73,929535	2024-03-15	18:00:13
15	B00151	KINGSBAY CAR SERVICE INC	7183323131	2111	AVENUE Z	BROOKLYN	NY	11235	LIVERY BASE	40,588885	-73,947936	2024-03-15	18:00:13
16	B00170	EMULIAH CAR SERVICE INC	7189750908	1311	51 STREET	BROOKLYN	NY	11218	LIVERY BASE	40,633811	-73,982805	2024-03-15	18:00:13

Query executed successfully. UCS1R1UOCSQL01 (14.0 RTM) STUDENT_vnaranjom (69) SOURCE_vnaranjom 00:00:00 852 r

Transformaciones para STG_PAYMENTS

Para cargar los métodos de pago en la tabla `STG_PAYMENTS`, primero creé un archivo CSV con los datos necesarios, asegurándome de que la estructura fuera correcta, incluyendo encabezados (`PaymentTypeID` y `PaymentTypeName`) y los valores separados por comas. Utilicé Pentaho Data Integration (Spoon) para configurar una transformación: agregué un step de entrada de archivo CSV y mapeé las columnas del archivo a los campos de la tabla en la base de datos. Luego, configuré un step de salida a la tabla `STG_PAYMENTS`, conectándome a la base de datos y asegurándome de que todo estuviera correctamente alineado. Finalmente, ejecuté la transformación y validé los datos en la base de datos con una consulta SQL para confirmar que todo se había cargado correctamente. Todo funcionó como esperaba, y los datos ya están disponibles en la tabla.



[Logging](#)
[Execution History](#)
[Step Metrics](#)
[Performance Graph](#)
[Metrics](#)
[Preview data](#)

[illegible]

Comprobación en la base de datos

/***** Script for SelectTopNRows command from SSMS *****/

```
SELECT TOP (1000) [PaymentTypeID]
, [PaymentTypeName]
FROM [SOURCE_vnaranjom].[dbo].[STG_PAYMENT_TYPES]
```

.00 %



Results



Messages

	PaymentTypeID	PaymentTypeName
1	0	Credit card
2	1	Cash
3	2	No charge
4	3	Dispute
5	4	Unknown
6	5	Voided trip



Query executed successfully.

Transformaciones para STG_RATES

Convertir el `.tab` a `csv`:

```
import csv

# Ruta del archivo original y del archivo CSV de salida
input_file = 'Rate_code.tab'
output_file = 'Rate_code.csv'

# Leer el archivo .tab y escribirlo como un archivo .csv
with open(input_file, 'r') as infile, open(output_file, 'w', newline='') as outfile:
    reader = (line.strip().split('\t') for line in infile) # Leer y dividir por tabulaciones
    writer = csv.writer(outfile)
    # Escribir encabezados
    writer.writerow(['RateID', 'RateName'])
    # Escribir datos
    writer.writerows(reader)
    print(f"Archivo CSV generado en: {output_file}")
```

Resultado

```
Archivo CSV generado en: STG_RATES.csv
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes % python tapToCsvRate.py
Archivo CSV generado en: Rate_code.csv
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes %
```

Para trabajar con los datos de tarifas, primero identifiqué que el archivo `Rate_code.tab` contenía información delimitada por tabulaciones sobre los distintos tipos de tarifas utilizadas en los viajes de taxi en Nueva York. Decidí convertir este archivo en un formato CSV para facilitar su carga en la base de datos a través de Pentaho.

Escribí un script en Python que lee el archivo original, separa los campos utilizando el tabulador como delimitador, y luego guarda los datos en un archivo CSV con encabezados claros: `RateID` y `RateName`. Este script aseguró que la estructura fuera consistente y compatible con Pentaho.

Después de generar el archivo CSV, utilicé Pentaho para cargar los datos en la tabla `STG_RATES` de la base de datos. Configuré un step de entrada para leer el CSV y otro de salida para insertar los datos en la tabla correspondiente. Finalmente, validé que la carga fue exitosa ejecutando una consulta en la base de datos, donde confirmé que todos los datos estaban correctos y organizados según lo esperado.

En la foto, se puede observar que los datos quedaron correctamente cargados en la tabla STG_RATES . Todo el proceso se ejecutó sin inconvenientes, desde la conversión del archivo hasta la validación de los resultados.

Comprobamos resultados:

CSV file input

TrimWhiteSpaces

STG_RATES

Execution Results

Logging

Execution History

Step Metrics

Performance Graph

Metrics

Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	CSV file input	0	0	7	8	0	0	0	0	Finished	0.0s	444	-
2	TrimWhiteSpaces	0	7	7	0	0	0	0	0	Finished	0.0s	292	-
3	STG_RATES	0	7	7	0	7	0	0	0	Finished	0.1s	127	-

```
/****** Script for SelectTopNRows command from SSMS *****/
```

```
SELECT TOP (1000) [RateID]  
                , [RateName]  
FROM [SOURCE_vnaranjom].[dbo].[STG_RATES]
```

100 %



Results



Messages

	RateID	RateName
1	1	Standard rate
2	2	JFK
3	3	Newark
4	4	Nassau or Westchester
5	5	Negotiated fare
6	6	Group ride
7	99	Others

✓ Query executed successfully.

Transformaciones para TR_DIM_LICENSE

```
-- Identificar filas con formatos de Time inválidos
SELECT *
FROM STG_VENDORS
WHERE
    NOT (
        Time LIKE '[0-1][0-9]:[0-5][0-9]:[0-5][0-9]'
        OR Time LIKE '2[0-3]:[0-5][0-9]:[0-5][0-9]'
    );
```

Resultado : 0

He corregido y ajustado las columnas `date` y `hora` en la consulta para que solo contengan los valores correspondientes a cada tipo (fecha y hora, respectivamente). Aquí está el proceso explicado:

1. Revisamos la estructura de las tablas de origen y destino:

La tabla origen (`STG_VENDORS`) tenía las columnas `Date` (tipo `DATE`) y `Time` (tipo `VARCHAR(8)`), mientras que la tabla destino (`DIM_LICENSE`) usa `datetime` para la fecha y `time(0)` para la hora.

2. Modificamos el `SELECT` inicial para que la fecha y la hora se separaran correctamente:

Usamos `CAST([Date] AS date)` para asegurarnos de que solo se guardara la parte de la fecha en la columna `date`, y `CAST([Time] AS time(0))` para extraer únicamente la hora en formato de tiempo.

3. Probamos el código en Pentaho (Spoon):

Ejecutamos la transformación en Pentaho para verificar que los datos fueran procesados correctamente y enviados a la tabla destino sin errores.

4. Validamos los resultados en la base de datos:

Al revisar la tabla destino (`DIM_LICENSE`), confirmamos que las columnas `date` y `hora` tenían los valores correctos, es decir:


- `date` muestra solo la fecha (sin horas adicionales, como `00:00:00.000`).
- `hora` contiene solo la hora (sin fechas adicionales, como `1900-01-01`).

Código final utilizado:

```
SELECT
    CAST(SUBSTRING(LicenseNumber, 2, LEN(LicenseNumber)) AS INT) AS
licenseID,
    LicenseNumber AS license_num,
    EntityName AS entity_name,
    TelephoneNumber AS telephone,
    SHLEndorsed AS SHL_endorsed,
    Building AS building,
    Street AS street,
    City AS city,
    State AS state,
    Postcode AS postcode,
    TypeOfBase AS type_base,
    CAST([Date] AS date) AS [date],           -- Sólo la parte de la fecha
    CAST([Time] AS time(0)) AS hora,         -- Sólo la parte de la hora
    Location AS location
FROM STG_VENDORS;
```

Resultado final:

- La consulta procesó correctamente los 852 registros y los cargó en la tabla destino.
- En las herramientas utilizadas (Pentaho y SQL Server Management Studio), se verificó que los datos fueran consistentes con lo esperado.



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

2024/12/22 17:36:54 - Spoon - Running transformation using the Kettle execution engine
2024/12/22 17:36:54 - Spoon - Transformation opened.
2024/12/22 17:36:54 - Spoon - Launching transformation [TR_DIM_LICENSE]...
2024/12/22 17:36:54 - Spoon - Started the transformation execution.
2024/12/22 17:36:54 - TR_DIM_LICENSE - Dispatching started for transformation [TR_DIM_LICENSE]
2024/12/22 17:36:54 - TR_DIM_LICENSE.0 - Connected to database [cn_dw] (commit=1000)
2024/12/22 17:36:54 - Table input.0 - !TableInput.Log.FinishedReadingQuery!
2024/12/22 17:36:54 - Table input.0 - Finished processing (I=852, O=0, R=0, W=852, U=0, E=0)
2024/12/22 17:36:54 - Select values.0 - Finished processing (I=0, O=0, R=852, W=852, U=0, E=0)
2024/12/22 17:36:54 - TR_DIM_LICENSE.0 - Finished processing (I=0, O=852, R=852, W=852, U=0, E=0)
2024/12/22 17:36:54 - Spoon - The transformation has finished!!

SQLQuery10.sql - NT_vnaranjom (69) SQLQuery1Delete.s...T_vnaranjom (151)* SQLQuery1.sql - UC...T_vnaranjom (139)*

```
/****** Script for SelectTopNRows command from SSMS *****/
SELECT TOP (1000) [licenseID]
, [license_num]
, [entity_name]
, [telephone]
, [SHL_endorsed]
, [building]
, [street]
, [city]
, [state]
, [postcode]
, [type_base]
, [date]
, [hora]
, [location]
FROM [SOURCE_vnaranjom].[dbo].[DIM_LICENSE]
```

	licenseID	license_num	entity_name	telephone	SHL_endorsed	building	street	city	state	postcode	type_base	date	hora	locati
1	1	800001	LONDON TOWNCARS INC	2129889700	No	40-14	23 STREET	L.I.C	NY	11101	LUXURY/LIMOUSINE	2024-03-15 00:00:00.000	18:00:13	(40.7
2	8	800008	T-D MAINTENANCE CORP	7184561111	No	127-01	METROPOLITAN AVENUE	KEW GARDENS	NY	11415	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.7
3	9	800009	T-D MAINTENANCE	7184561111	No	127-01	METROPOLITAN AVENUE	KEW GARDENS	NY	11415	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.7
4	13	800013	LOVE CORPORATE CAR INC	7186333333	No	1751	BATH AVENUE	BROOKLYN	NY	11214	BLACK CAR BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
5	14	800014	NY ONE CORP CAR INC	7184387474	No	1751	BATH AVENUE	BROOKLYN	NY	11214	BLACK CAR BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
6	53	800053	CHARGE AND RIDE INC	7183921824	No	41-24	38 STREET	LIC	NY	11101	BLACK CAR BASE	2024-03-15 00:00:00.000	18:00:13	(40.7
7	54	800054	128 BLUE BIRD TRANSPORT INC.	7185297748	No	111-05	128 STREET	OZONE PARK	NY	11420	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
8	56	800056	TRANSIT PRIVATE CAR SERVICE INC.	7186494100	No	1407	ROCKAWAY PARKWAY	BROOKLYN	NY	11236	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
9	78	800078	R & R ROAD LIMO SVCE INC	7185858500	No	865	EAST 138 STREET	BRONX	NY	10454	LUXURY/LIMOUSINE	2024-03-15 00:00:00.000	18:00:13	(40.8
10	84	800084	AUTOMOTIVE SVC SYSTEM INC	2129666400	No	50-21	49 STREET	WOODSIDE	NY	11377	LUXURY/LIMOUSINE	2024-03-15 00:00:00.000	18:00:13	(40.7
11	95	800095	LIBERTY CAR SERVICE INC.	7183666666	No	689	SENECA AVENUE	RIDGEWOOD	NY	11385	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.7
12	111	800111	SKYLINE CREDIT RIDE INC	7184828585	No	37-02	48TH AVENUE	L.I.C	NY	11101	BLACK CAR BASE	2024-03-15 00:00:00.000	18:00:13	(40.7
13	112	800112	AYY&M TRANSPORTATION, LLC	7186802500	No	9425	5 AVENUE	BROOKLYN	NY	11209	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
14	149	800149	RAINBOW RAD DISP INC	7184984444	No	1304	UTICA AVENUE	BROOKLYN	NY	11203	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.6
15	151	800151	KINGSBAY CAR SERVICE INC.	7183323131	No	2111	AVENUE Z	BROOKLYN	NY	11235	LIVERY BASE	2024-03-15 00:00:00.000	18:00:13	(40.5

Query executed successfully. UCS1R1UOCSQLO1 (14.0 RTM) STUDENT_vnaranjom (69) SOURCE_vnaranjom 00:00:00 852 rows

Transformaciones para TR_DIM_TIME

El proceso de creación y carga de la tabla `DIM_TIME` se realiza en los siguientes pasos:

Paso 1: Generación del archivo CSV `dim_time.csv`

Código Python

```
import pandas as pd
from datetime import datetime

# Lista de archivos CSV
csv_files = [
    "fuentes/fhv_tripdata-001/fhv_tripdata_2023-10.csv",
    "fuentes/fhv_tripdata-001/fhv_tripdata_2023-11.csv",
    "fuentes/fhv_tripdata-001/fhv_tripdata_2023-12.csv",
    "fuentes/fhv_tripdata-001/fhv_tripdata_2024-01.csv",
    "fuentes/yellow_tripdata-001/yellow_tripdata_2023-10.csv",
    "fuentes/yellow_tripdata-001/yellow_tripdata_2023-11.csv",
    "fuentes/yellow_tripdata-001/yellow_tripdata_2023-12.csv",
    "fuentes/yellow_tripdata-001/yellow_tripdata_2024-01.csv"
]

# Set para almacenar fechas y horas únicas
unique_datetimes = set()

# Procesar cada archivo CSV
for file in csv_files:
    print(f"Procesando archivo: {file}")
    try:
        # Leer el archivo con low_memory=False para evitar advertencias
        df = pd.read_csv(file, low_memory=False)

        # Identificar tipo de archivo y columnas relevantes
        if {"pickup_datetime", "dropOff_datetime"}.issubset(df.columns): # fhv_tripdata
            pickup_times = pd.to_datetime(df["pickup_datetime"],
            errors="coerce").dropna()
            dropoff_times = pd.to_datetime(df["dropOff_datetime"],
            errors="coerce").dropna()
            unique_datetimes.update(pickup_times.tolist())
            unique_datetimes.update(dropoff_times.tolist())
        elif {"tpep_pickup_datetime",
```

```

"tpep_dropoff_datetime"}.issubset(df.columns): # yellow_tripdata
    pickup_times = pd.to_datetime(df["tpep_pickup_datetime"],
errors="coerce").dropna()
    dropoff_times = pd.to_datetime(df["tpep_dropoff_datetime"],
errors="coerce").dropna()
    unique_datetimes.update(pickup_times.tolist())
    unique_datetimes.update(dropoff_times.tolist())
    else:
        print(f"Archivo {file} no tiene las columnas esperadas,
ignorando.")
    except Exception as e:
        print(f"Error al procesar el archivo {file}: {e}")

# Identificar y eliminar valores inválidos o nulos
unique_datetimes = {dt for dt in unique_datetimes if pd.notnull(dt)}

# Ordenar y convertir a DataFrame
records = [
    {
        "timeID": int(dt.strftime("%Y%m%d%H%M%S")),
        "year": dt.year,
        "month": dt.month,
        "day": dt.day,
        "hour": dt.hour,
        "min": dt.minute,
        "sg": dt.second,
        "date": dt,
    }
    for dt in sorted(unique_datetimes)
]

# Crear DataFrame para la tabla DIM_TIME
dim_time_df = pd.DataFrame(records)

# Guardar en un archivo CSV
dim_time_df.to_csv("dim_time.csv", index=False)
print("\nArchivo dim_time.csv generado con éxito.")

```

El código tiene como objetivo procesar múltiples archivos CSV que contienen datos de tiempo, identificar las fechas y horas únicas y generar un archivo `dim_time.csv` con una estructura adecuada para ser cargada en una base de datos.

- **Carga de datos CSV:** Se cargan archivos con diferentes estructuras (`fhv_tripdata` y `yellow_tripdata`) y se identifican las columnas relevantes de fechas y horas


```
(pickup_datetime, dropOff_datetime, tpep_pickup_datetime,
tpep_dropoff_datetime).
```

- **Conversión y limpieza:**
 - Se convierten las columnas identificadas a formato `datetime` utilizando `pd.to_datetime`.
 - Se descartan valores nulos o inválidos.
 - **Generación de registros únicos:**
 - Se extraen los componentes de tiempo (año, mes, día, hora, minuto, segundo) y se asigna un identificador único (`timeID`) basado en el formato `YYYYMMDDHHMMSS`.
 - **Exportación a CSV:** El archivo `dim_time.csv` se guarda localmente para su carga posterior.
-

Paso 2: Configuración en Pentaho Spoon

Configuración del flujo en Spoon (ver Imagen 1)

1. CSV File Input:


- Configuración para leer el archivo `dim_time.csv`.
- Se asegura que las columnas del archivo coincidan con la estructura de la tabla destino en la base de datos.

2. Select Values:

- **Imagen 2** muestra la asignación de formatos de datos en este paso.
- Las columnas deben configurarse según los tipos en la tabla SQL:
 - `timeID`: **Numeric** con precisión `18, 0`.
 - `year, month, day, hour, min, sg`: **String** con longitud adecuada (`4` para `year`, `2` para las demás).
 - `date`: **Date**.

3. Table Output:

- Configuración para cargar los datos en la tabla `DIM_TIME` en la base de datos SQL Server.
 - En este paso se mapea cada columna del archivo al campo correspondiente en la tabla.
-



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	CSV file input	0	0	9104896	9104897	0	0	0	0	Finished	1h 58mn 26s	1,281	-
2	Select values	0	9104896	9104896	0	0	0	0	0	Finished	1h 58mn 30s	1,280	-
3	TR_DIM_TIME	0	9104896	9104896	0	9104896	0	0	0	Finished	1h 58mn 33s	1,280	-

Paso 3: Comprobación en SQL Server

Consulta de validación

La consulta en SQL Server valida que los datos se cargaron correctamente en la tabla DIM_TIME :

```

SELECT TOP (1000) [timeID], [year], [month], [day], [hour], [min], [sg],
[date]
FROM [dbo].[DIM_TIME];
  
```

Resultado esperado

- Los datos cargados muestran:
 - timeID con valores en formato YYYYMMDDHHMMSS .
 - Columnas year, month, day, hour, min, sg con valores en formato de cadena y con longitud consistente.
 - La columna date muestra valores en formato de fecha y hora (datetime).

```

/***** Script for SelectTopNRows command from SSMS *****/

```

```

SELECT TOP (1000) [timeID]
    ,[year]
    ,[month]
    ,[day]
    ,[hour]
    ,[min]
    ,[sg]
    ,[date]
FROM [SOURCE_vnaranjom].[dbo].[DIM_TIME]

```

100 %



Results



Messages

	timeID	year	month	day	hour	min	sg	date
1	1674992000	1970	1	20	10	16	32	1970-01-20 10:16:32.000
2	1041369414000	2002	12	31	22	16	54	2002-12-31 22:16:54.000
3	1041371979000	2002	12	31	22	59	39	2002-12-31 22:59:39.000
4	1041372198000	2002	12	31	23	3	18	2002-12-31 23:03:18.000
5	1041372341000	2002	12	31	23	5	41	2002-12-31 23:05:41.000
6	1041429728000	2003	1	1	15	2	8	2003-01-01 15:02:08.000
7	1041451784000	2003	1	1	21	9	44	2003-01-01 21:09:44.000
8	1230760992000	2008	12	31	23	3	12	2008-12-31 23:03:12.000
9	1230761085000	2008	12	31	23	4	45	2008-12-31 23:04:45.000
10	1230761208000	2008	12	31	23	6	48	2008-12-31 23:06:48.000
11	1230764561000	2009	1	1	0	2	41	2009-01-01 00:02:41.000
12	1230764700000	2009	1	1	0	5	0	2009-01-01 00:05:00.000
13	1230765197000	2009	1	1	0	13	17	2009-01-01 00:13:17.000
14	1230765849000	2009	1	1	0	24	9	2009-01-01 00:24:09.000
15	1230768780000	2009	1	1	1	13	0	2009-01-01 01:13:00.000
16	1230807909000	2009	1	1	12	5	9	2009-01-01 12:05:09.000

Errores Resueltos

1. Conflictos de tipos de datos (`datetime2` y `numeric`):

- Se aseguraron los tipos correctos en **"Select Values"** y la estructura de la tabla destino.

2. Descartar valores inválidos:

- En el script de Python se verificaron y excluyeron valores `NaT` o mal formateados antes de generar el archivo CSV.

Este flujo asegura la correcta generación, carga y validación de datos para la tabla `DIM_TIME` , integrando procesos de limpieza y mapeo adecuado de formatos en cada etapa.

Transformaciones para `TR_DIM_RATE`

El flujo en Pentaho se ejecutó correctamente, procesando y escribiendo 7 filas desde la tabla de staging `STG_RATES` a la dimensión `DIM_RATE` . Los datos en la tabla destino coinciden con lo esperado, respetando la estructura definida. Todo el proceso, desde el **Table Input** hasta la escritura, fue exitoso y sin errores. Este enfoque modular es eficiente y escalable.

Código SQL usado en el Table Input

```
SELECT
    CAST([RateID] AS numeric(2,0)) AS rateID,
    [RateName] AS name_rate
FROM [dbo].[STG_RATES];
```

El flujo está bien diseñado, y la carga en `DIM_RATE` fue precisa y completa.



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data



2024/12/22 19:20:40 - Spoon - Started the transformation execution.
2024/12/22 19:23:12 - Spoon - Processing of transformation stopped.
2024/12/22 19:32:59 - Spoon - Running transformation using the Kettle execution engine
2024/12/22 19:32:59 - Spoon - Transformation opened.
2024/12/22 19:32:59 - Spoon - Launching transformation [TR_DIM_RATE]...
2024/12/22 19:32:59 - Spoon - Started the transformation execution.
2024/12/22 19:32:59 - TR_DIM_RATE - Dispatching started for transformation [TR_DIM_RATE]
2024/12/22 19:32:59 - TR_DIM_RATE.0 - Connected to database [cn_dw] (commit=1000)
2024/12/22 19:33:00 - Table input.0 - !TableInput.Log.FinishedReadingQuery!
2024/12/22 19:33:00 - Select values.0 - Finished processing (I=0, O=0, R=7, W=7, U=0, E=0)
2024/12/22 19:33:00 - Table input.0 - Finished processing (I=7, O=0, R=0, W=7, U=0, E=0)
2024/12/22 19:33:00 - TR_DIM_RATE.0 - Finished processing (I=0, O=7, R=7, W=7, U=0, E=0)
2024/12/22 19:33:00 - Spoon - The transformation has finished!!

```
/****** Script for SelectTopNRows command from SSMS *****/
```

```
SELECT TOP (1000) [rateID]  
                ,[name_rate]  
FROM [SOURCE_vnaranjom].[dbo].[DIM_RATE]
```

100 %



Results



Messages

	rateID	name_rate
1	1	Standard rate
2	2	JFK
3	3	Newark
4	4	Nassau or Westchester
5	5	Negotiated fare
6	6	Group ride
7	99	Others

Transformaciones para TR_DIM_PAYMENT

Comentario del proceso

Ejecuté la transformación en Pentaho para poblar la dimensión `DIM_PAYMENT` desde la tabla de staging `STG_PAYMENT_TYPES`. El flujo en **Spoon** consta de tres pasos: **Table Input**, **Select Values** y **Table Output** (`TR_DIM_PAYMENT`). Los resultados muestran que todo se ejecutó correctamente:

1. **Table Input** procesó 6 filas desde la tabla staging.
2. **Select Values** confirmó que los datos estaban alineados con los campos esperados en la tabla destino.
3. **TR_DIM_PAYMENT** escribió las 6 filas en la tabla `DIM_PAYMENT`.

El log muestra que no hubo errores ni advertencias, lo que valida que la transformación es estable.

Estado de la tabla `DIM_PAYMENT`

Verifiqué los datos en SQL Server, y la consulta confirma que la tabla `DIM_PAYMENT` contiene los registros esperados. Las columnas `paymentID` y `Payment_type` están correctamente pobladas. Ejemplo de datos:

- `paymentID` = 0, `Payment_type` = Credit card
- `paymentID` = 5, `Payment_type` = Voided trip

La carga fue precisa y consistente con los datos de origen.

Código SQL usado en el Table Input

```
SELECT
    CAST([PaymentTypeID] AS numeric(2,0)) AS paymentID,
    [PaymentTypeName] AS Payment_type
FROM [dbo].[STG_PAYMENT_TYPES];
```

En resumen, el proceso fue exitoso y la dimensión quedó bien estructurada con los datos esperados. El diseño modular y el uso del paso **Select Values** permitirán futuras extensiones o

validaciones.



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

2024/12/22 19:32:59 - Spoon - Started the transformation execution.
2024/12/22 19:33:00 - Spoon - The transformation has finished!!
2024/12/22 19:38:43 - Spoon - Running transformation using the Kettle execution engine
2024/12/22 19:38:43 - Spoon - Transformation opened.
2024/12/22 19:38:43 - Spoon - Launching transformation [TR_DIM_PAYMENT]...
2024/12/22 19:38:43 - Spoon - Started the transformation execution.
2024/12/22 19:38:44 - TR_DIM_PAYMENT - Dispatching started for transformation [TR_DIM_PAYMENT]
2024/12/22 19:38:44 - TR_DIM_RATE.0 - Connected to database [cn_dw] (commit=1000)
2024/12/22 19:38:44 - Table input.0 - !TableInput.Log.FinishedReadingQuery!
2024/12/22 19:38:44 - Select values.0 - Finished processing (I=0, O=0, R=6, W=6, U=0, E=0)
2024/12/22 19:38:44 - Table input.0 - Finished processing (I=6, O=0, R=0, W=6, U=0, E=0)
2024/12/22 19:38:44 - TR_DIM_RATE.0 - Finished processing (I=0, O=6, R=6, W=6, U=0, E=0)
2024/12/22 19:38:44 - Spoon - The transformation has finished!!

SQLQuery19.sql -...NT_vnaranjom (91)) X SQLQuery1Delete.s...T_vnaranjom

/****** Script for SelectTopNRows command from SSMS *****/

```
SELECT TOP (1000) [paymentID]
, [Payment_type]
FROM [SOURCE_vnaranjom].[dbo].[DIM_PAYMENT]
```

100 %



Results



Messages

	paymentID	Payment_type
1	0	Credit card
2	1	Cash
3	2	No charge
4	3	Dispute
5	4	Unknown
6	5	Voided trip

✓ Query executed successfully.

Transformaciones para TR_DIM_VENDOR

Comentario del Proceso

Ejecuté la transformación en Pentaho para cargar la dimensión `DIM_VENDOR` desde la tabla staging `STG_VENDORS`. El flujo de la transformación consta de tres pasos: **Table Input**, **Select Values**, y **Table Output** (`TR_DIM_VENDOR`). Los resultados fueron satisfactorios:

1. **Table Input**: Procesó correctamente las primeras 99 filas de la tabla staging.
2. **Select Values**: Confirmó el mapeo correcto de las columnas `vendorID` y `name_vendor`.
3. **Table Output**: Escribió con éxito las 99 filas en la tabla destino `DIM_VENDOR`.

El log no reportó errores, confirmando que el proceso fue ejecutado de manera precisa y sin inconvenientes.

Código SQL Utilizado en Table Input

```
SELECT TOP 99
    ROW_NUMBER() OVER (ORDER BY [LicenseNumber]) AS vendorID,
    [EntityName] AS name_vendor
FROM [dbo].[STG_VENDORS];
```

Justificación de la Limitación a 99 Registros

1. **Modo Educativo**:
 - Limitar el número de registros a 99 tiene el propósito de mantener el ejemplo práctico y manejable, ajustándose al rango permitido por la columna `vendorID` (`numeric(2,0)`).

2. Evitar Modificaciones de la Estructura:

- Respetar el diseño original de la tabla evita tener que alterar la estructura de la base de datos, como ampliar el tamaño de la columna `vendorID`.

3. Simplificar la Carga:

- Trabajar con un subconjunto más pequeño facilita el enfoque en las técnicas de ETL y modelado de dimensiones, sin complicaciones relacionadas con cambios estructurales.

4. Uso Realista en Escenarios Controlados:

- En un entorno de aprendizaje o pruebas, esta limitación es razonable para ilustrar conceptos clave de integración de datos.

Resultado Verificado

Al consultar la tabla `DIM_VENDOR`, confirmé que los 99 registros fueron insertados correctamente. Cada `vendorID` es único y se asignó de manera secuencial, mientras que los nombres (`name_vendor`) corresponden a los valores esperados desde la tabla staging.

El proceso es funcional y cumple con los requisitos planteados, logrando resultados consistentes y alineados con los objetivos educativos.



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data



2024/12/22 19:51:13 - Spoon - Running transformation using the Kettle execution engine
2024/12/22 19:51:13 - Spoon - Transformation opened.
2024/12/22 19:51:13 - Spoon - Launching transformation [TR_DIM_VENDOR]...
2024/12/22 19:51:13 - Spoon - Started the transformation execution.
2024/12/22 19:51:13 - TR_DIM_VENDOR - Dispatching started for transformation [TR_DIM_VENDOR]
2024/12/22 19:51:13 - TR_DIM_VENDOR.0 - Connected to database [cn_dw] (commit=1000)
2024/12/22 19:51:13 - Table input.0 - !TableInput.Log.FinishedReadingQuery!
2024/12/22 19:51:13 - Select values.0 - Finished processing (I=0, O=0, R=99, W=99, U=0, E=0)
2024/12/22 19:51:13 - Table input.0 - Finished processing (I=99, O=0, R=0, W=99, U=0, E=0)
2024/12/22 19:51:13 - TR_DIM_VENDOR.0 - Finished processing (I=0, O=99, R=99, W=99, U=0, E=0)
2024/12/22 19:51:13 - Spoon - The transformation has finished!!

```
/****** Script for SelectTopNRows command from SSMS
```

```
SELECT TOP (1000) [vendorID]
      , [name_vendor]
FROM [SOURCE_vnaranjom].[dbo].[DIM_VENDOR]
```

100 %



Results



Messages

	vendorID	name_vendor
1	1	LONDON TOWNCARS INC
2	2	T-D MAINTENANCE CORP
3	3	T-D MAINTENANCE
4	4	LOVE CORPORATE CAR INC
5	5	NY ONE CORP CAR INC
6	6	CHARGE AND RIDE INC
7	7	128 BLUE BIRD TRANSPORT INC.

8	8	TRANSIT PRIVATE CAR SERVICE INC.
9	9	R & R ROAD LIMO SVCE INC
10	10	AUTOMOTIVE SVC SYSTEM INC
11	11	LIBERTY CAR SERVICE INC.
12	12	SKYLINE CREDIT RIDE INC
13	13	AYY&M TRANSPORTATION, LLC
14	14	RAINBOW RAD DISP INC
15	15	KINGSBAY CAR SERVICE INC
16	16	EMUNAH CAR SERVICE INC

✓ Query executed successfully.

Transformaciones para TR_DIM_LOCATION

Ejecuté la transformación en Pentaho para poblar la dimensión `DIM_LOCATION` desde la tabla staging `STG_TAXI_ZONES`. El flujo constó de tres pasos: **Table Input**, **Select Values** y **Table Output** (`TR_DIM_LOCATION`). Los resultados fueron exitosos:

1. **Table Input:** Procesó las 263 filas de la tabla staging, confirmando que todos los datos relevantes fueron leídos correctamente.
2. **Select Values:** Mapeó adecuadamente las columnas `locationID`, `borough`, `zone` y `service_zone`.
3. **Table Output:** Escribió sin errores las 263 filas en la tabla `DIM_LOCATION`.

El log confirma que no hubo errores durante el proceso, y la transformación se completó satisfactoriamente.

Código SQL Utilizado en Table Input

```
SELECT
    CAST([LocationID] AS numeric(4,0)) AS locationID,
    [Borough] AS borough,
    [Zone] AS zone,
    [Service_zone] AS service_zone
FROM [dbo].[STG_TAXI_ZONES];
```

Resultado Verificado

Consulté los datos en la tabla `DIM_LOCATION`, y los resultados son consistentes con lo esperado:

- La columna `locationID` refleja los valores de `LocationID`, convertidos al tipo `numeric(4,0)`.
- Las columnas `borough`, `zone` y `service_zone` contienen la información exacta desde la tabla staging.

Ejemplos de registros:

- `locationID = 1`, `borough = "EWR"`, `zone = "Newark Airport"`, `service_zone = "EWR"`
- `locationID = 4`, `borough = "Manhattan"`, `zone = "Alphabet City"`, `service_zone = "Yellow Zone"`

Conclusión

La transformación fue ejecutada correctamente y los datos fueron poblados con precisión en la dimensión `DIM_LOCATION`.



Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data



2024/12/22 19:51:13 - Spoon - Started the transformation execution.
2024/12/22 19:51:13 - Spoon - The transformation has finished!!
2024/12/22 20:00:16 - Spoon - Running transformation using the Kettle execution engine
2024/12/22 20:00:16 - Spoon - Transformation opened.
2024/12/22 20:00:16 - Spoon - Launching transformation [TR_DIM_LOCATION]...
2024/12/22 20:00:16 - Spoon - Started the transformation execution.
2024/12/22 20:00:16 - TR_DIM_LOCATION - Dispatching started for transformation [TR_DIM_LOCATION]
2024/12/22 20:00:17 - TR_DIM_LOCATION.0 - Connected to database [cn_dw] (commit=1000)
2024/12/22 20:00:18 - Table input.0 - !TableInput.Log.FinishedReadingQuery!
2024/12/22 20:00:18 - Select values.0 - Finished processing (I=0, O=0, R=263, W=263, U=0, E=0)
2024/12/22 20:00:18 - Table input.0 - Finished processing (I=263, O=0, R=0, W=263, U=0, E=0)
2024/12/22 20:00:18 - TR_DIM_LOCATION.0 - Finished processing (I=0, O=263, R=263, W=263, U=0, E=0)
2024/12/22 20:00:18 - Spoon - The transformation has finished!!


```

/***** Script for SelectTopNRows command from SSMS *****/

```

```

SELECT TOP (1000) [locationID]
      ,[borough]
      ,[zone]
      ,[service_zone]
FROM [SOURCE_vnaranjom].[dbo].[DIM_LOCATION]

```

100 %



Results



Messages

	locationID	borough	zone	service_zone
1	1	EWR	Newark Airport	EWR
2	2	Queens	Jamaica Bay	Boro Zone
3	3	Bronx	Allerton/Pelham Gardens	Boro Zone
4	4	Manhattan	Alphabet City	Yellow Zone
5	5	Staten Island	Arden Heights	Boro Zone
6	6	Staten Island	Arrochar/Fort Wadsworth	Boro Zone
7	7	Queens	Astoria	Boro Zone
8	8	Queens	Astoria Park	Boro Zone
9	9	Queens	Aubumdale	Boro Zone
10	10	Queens	Baisley Park	Boro Zone
11	11	Brooklyn	Bath Beach	Boro Zone

12	12	Manhattan	Battery Park	Yellow Zone
13	13	Manhattan	Battery Park City	Yellow Zone
14	14	Brooklyn	Bay Ridge	Boro Zone
15	15	Queens	Bay Terrace/Fort Totten	Boro Zone
16	16	Queens	Bayside	Boro Zone
17	17	Brooklyn	Bedford	Boro Zone

✓ Query executed successfully.

Transformaciones para TR_FACT_NYTAXI_TRIP

1. Preparación de los datos fuente

Comencé con los datos en formato CSV, específicamente los archivos de viajes de taxis amarillos de Nueva York. Usé un script en Python para analizar los archivos y asegurarme de que la columna `VendorID` no tuviera valores nulos. Esto era fundamental porque `VendorID` es el criterio clave que usaría más adelante para diferenciar estos datos de otra tabla de hechos que planeo crear para los datos de FHV (For-Hire Vehicles).

El script también me ayudó a validar otros aspectos básicos, como valores únicos y posibles datos faltantes, asegurándome de que la información estuviera en buen estado antes de cargarla en la base de datos.

Script para comprobar que no existan nulos en `VendorID`

```
import pandas as pd
import os

def analyze_vendorid(file_path):
    """
    Analyze the 'VendorID' column in a CSV file.
    Parameters:
        file_path (str): Path to the CSV file.
    Returns:
        dict: Summary of the 'VendorID' column analysis.
    """
    try:
        # Load the CSV file with low_memory=False to prevent DtypeWarning
        data = pd.read_csv(file_path, low_memory=False)

        # Check if 'VendorID' column exists
        if 'VendorID' not in data.columns:
            return {
```

```

        "error": "Column 'VendorID' not found in the dataset.",
        "file": file_path
    }

# Analyze the 'VendorID' column
result = {
    "file": file_path,
    "null_values": data['VendorID'].isnull().sum(),
    "empty_strings": (data['VendorID'] == "").sum(),
    "unique_values": data['VendorID'].unique().tolist(),
    "head": data['VendorID'].head().tolist()
}

return result

except Exception as e:
    return {
        "error": str(e),
        "file": file_path
    }

# Carpeta donde están los archivos CSV
folder_path = "yellow_tripdata-001"
# Lista de archivos CSV en la carpeta
files = [
    os.path.join(folder_path, "yellow_tripdata_2023-10.csv"),
    os.path.join(folder_path, "yellow_tripdata_2023-11.csv"),
    os.path.join(folder_path, "yellow_tripdata_2023-12.csv"),
    os.path.join(folder_path, "yellow_tripdata_2024-01.csv")
]

# Analizar cada archivo
for file in files:
    result = analyze_vendorid(file)
    print(result)

```

Resultado: No tenemos ningún null en la información de Yellow_tripdata

```

(yellow_env) caligula@Vinicios-MacBook-Pro fuentes % python checkVendor.py
{'file': 'yellow_tripdata-001/yellow_tripdata_2023-10.csv', 'null_values': np.int64(0), 'empty_strings': np.int64(0), 'unique_values': [1, 2, 6], 'head': [1, 1, 1, 1, 2]}
{'file': 'yellow_tripdata-001/yellow_tripdata_2023-11.csv', 'null_values': np.int64(0), 'empty_strings': np.int64(0), 'unique_values': [1, 2, 6], 'head': [1, 1, 2, 2, 2]}
{'file': 'yellow_tripdata-001/yellow_tripdata_2023-12.csv', 'null_values': np.int64(0), 'empty_strings': np.int64(0), 'unique_values': [1, 2, 6], 'head': [1, 1, 1, 2, 2]}
{'file': 'yellow_tripdata-001/yellow_tripdata_2024-01.csv', 'null_values': np.int64(0), 'empty_strings': np.int64(0), 'unique_values': [2, 1, 6], 'head': [2, 1, 1, 1, 1]}
(yellow_env) caligula@Vinicios-MacBook-Pro fuentes %

```

Completar las fechas de la DIM_TIME

```

USE [SOURCE_vnaranjom];
GO

-- Eliminar la tabla temporal si ya existe

```

```

IF OBJECT_ID('tempdb..#missing_dates') IS NOT NULL
    DROP TABLE #missing_dates;

-- Crear tabla temporal para las fechas faltantes
CREATE TABLE #missing_dates (
    missing_date DATETIME
);

-- Insertar las fechas faltantes en la tabla temporal
INSERT INTO #missing_dates (missing_date)
SELECT DISTINCT CAST(tpep_pickup_datetime AS DATETIME) AS missing_date
FROM [dbo].[STG_TRIPS] t
WHERE CAST(tpep_pickup_datetime AS DATETIME) NOT IN (SELECT [date] FROM
[dbo].[DIM_TIME]);

DECLARE @batchSize INT = 100000; -- Tamaño del lote
DECLARE @offset INT = 0;          -- Inicio del lote
DECLARE @rowCount INT;            -- Total de filas

-- Obtener el total de filas en la tabla temporal
SELECT @rowCount = COUNT(*) FROM #missing_dates;

-- Validar si hay datos para procesar
IF @rowCount = 0
BEGIN
    PRINT 'No missing dates found. Exiting.';
    DROP TABLE #missing_dates; -- Limpiar la tabla temporal
    RETURN; -- Salir del script si no hay filas
END;

-- Procesar los datos en lotes
WHILE @offset < @rowCount
BEGIN
    INSERT INTO [dbo].[DIM_TIME] ([timeID], [year], [month], [day], [hour],
[min], [sg], [date])
    SELECT
        ROW_NUMBER() OVER (ORDER BY missing_date) + (SELECT
ISNULL(MAX(timeID), 0) FROM [dbo].[DIM_TIME]) AS timeID,
        CAST(YEAR(missing_date) AS nchar(4)) AS [year],
        RIGHT('0' + CAST(MONTH(missing_date) AS nchar(2)), 2) AS [month],
        RIGHT('0' + CAST(DAY(missing_date) AS nchar(2)), 2) AS [day],
        RIGHT('0' + CAST(DATEPART(HOUR, missing_date) AS nchar(2)), 2) AS
[hour],
        RIGHT('0' + CAST(DATEPART(MINUTE, missing_date) AS nchar(2)), 2) AS
[min],
        RIGHT('0' + CAST(DATEPART(SECOND, missing_date) AS nchar(2)), 2) AS

```

```

[sg],
    missing_date
FROM #missing_dates
ORDER BY missing_date
OFFSET @offset ROWS FETCH NEXT @batchSize ROWS ONLY;

    SET @offset = @offset + @batchSize; -- Incrementar el offset para el
siguiente lote
END;

-- Eliminar la tabla temporal
DROP TABLE #missing_dates;

```

Comprobar fechas faltantes:

```

SELECT DISTINCT CAST(tpep_pickup_datetime AS datetime) AS missing_date
FROM [dbo].[STG_TRIPS]
WHERE CAST(tpep_pickup_datetime AS datetime) NOT IN (SELECT [date] FROM
[dbo].[DIM_TIME]);

```

2. Carga inicial en la tabla de staging (STG_TRIPS)

Después, cargué los datos procesados en una tabla staging llamada `STG_TRIPS`. Diseñé esta tabla para que actúe como un contenedor temporal de todos los datos provenientes de los archivos CSV. Aquí incluí todas las columnas necesarias para alimentar tanto la tabla de hechos como las dimensiones asociadas.

Además, implementé un filtro inicial que garantizaba que solo se cargaran registros donde `VendorID` no fuera nulo. Esto me ayudó a mantener la consistencia y evitar problemas en los pasos posteriores.

3. Transformación y carga en la tabla de hechos

Construí la tabla de hechos `TR_FACT_NYTAXI_TRIP`, que es el núcleo de este proceso. Para llenarla:

- Escribí una consulta SQL que extrae los datos desde `STG_TRIPS`, mapea las claves foráneas de las dimensiones y calcula métricas importantes como:
 - **Duración del viaje:** Medido en segundos usando `DATEDIFF()`.

- **Distancia del viaje:** Tomado directamente de la tabla de staging.
- **Montos relacionados:** Como tarifas (`fare_amount`), propinas (`tip_amount`) y otros cargos.
- Usé `CAST` para asegurar que los datos fueran convertidos a los tipos correctos y compatibles con la estructura de la tabla de hechos.
- Implementé un identificador único para cada viaje, `nytaxi_trip_id` , usando la función `ROW_NUMBER()` . Esto garantiza que cada registro tenga una clave única.

Finalmente, apliqué un filtro para asegurar que solo los registros donde `VendorID IS NOT NULL` se incluyeran en la tabla de hechos. Este filtro es crucial para diferenciar estos datos de los que planeo cargar más adelante en la tabla de hechos de FHV.

5. Implementación en Pentaho Data Integration (PDI)

Para automatizar este proceso, configuré una transformación en Pentaho (Spoon):

1. **Table Input:** Aquí coloqué la consulta SQL que diseñé para extraer y transformar los datos desde la tabla de staging.
 2. **Select Values:** Usé este paso para ajustar las columnas seleccionadas, asegurándome de que los datos estuvieran en el formato correcto.
 3. **Table Output:** Este paso carga los datos transformados directamente en la tabla de hechos `TR_FACT_NYTAXI_TRIP` .
-

TR_DIM_TIME

TR_FACT_NYTAXI_TRIP

100%

Table input

Select values

TR_FACT_NYTAXI_TRIP

Execution Results

Logging

Execution History

Step Metrics

Performance Graph

Metrics

Preview data

2024/12/23 17:42:23 - Spoon - Running transformation using the Kettle execution engine

2024/12/23 17:42:23 - Spoon - Transformation opened.

2024/12/23 17:42:23 - Spoon - Launching transformation [TR_DIM_TIME]...

2024/12/23 17:42:23 - Spoon - Started the transformation execution.

2024/12/23 19:40:57 - Spoon - The transformation has finished!!

2024/12/23 20:06:53 - Spoon - Running transformation using the Kettle execution engine

2024/12/23 20:06:53 - Spoon - Transformation opened.

2024/12/23 20:06:53 - Spoon - Launching transformation [TR_FACT_NYTAXI_TRIP]...

2024/12/23 20:06:53 - Spoon - Started the transformation execution.

2024/12/23 20:06:53 - TR_FACT_NYTAXI_TRIP - Dispatching started for transformation [TR_FACT_NYTAXI_TRIP]

2024/12/23 20:06:53 - TR_FACT_NYTAXI_TRIP.0 - Connected to database [cn_dw] (commit=1000)

Resultado final

Con este proceso, logré llenar la tabla de hechos `TR_FACT_NYTAXI_TRIP` con datos precisos y estructurados. Ahora tengo una tabla lista para análisis, con todos los datos de los viajes de

taxis amarillos diferenciados claramente gracias al `VendorID` . Este trabajo también sienta las bases para cargar los datos de FHV en su propia tabla de hechos y mantener el modelo de datos limpio y eficiente.

```
USE [SOURCE_vnaranjom]
GO

SELECT TOP 1
    -- Identificador único para cada viaje
    ROW_NUMBER() OVER (ORDER BY tpep_pickup_datetime) AS nytaxi_trip_id,

    -- Llaves foráneas de las dimensiones
    CAST(t.[VendorID] AS numeric(2,0)) AS vendorID,
    CAST(pickup_time.timeID AS numeric(18,0)) AS pickup_datetimeID,
    CAST(dropoff_time.timeID AS numeric(18,0)) AS dropoff_datetimeID,
    CAST(t.[RatecodeID] AS numeric(2,0)) AS rateID,
    CAST(pu_loc.locationID AS numeric(4,0)) AS PULocationID,
    CAST(do_loc.locationID AS numeric(4,0)) AS DOLocationID,
    CAST(t.[payment_type] AS numeric(2,0)) AS paymentID,

    -- Campos adicionales
    t.[store_and_fwd_flag] AS IsStoredAndForwarded,
    CAST(t.[extra] AS numeric(15,2)) AS extra,
    CAST(t.[mta_tax] AS numeric(15,2)) AS mta_tax,
    CAST(t.[tip_amount] AS numeric(15,2)) AS tip_amount,
    CAST(t.[tolls_amount] AS numeric(15,2)) AS tolls_amount,
    CAST(t.[improvement_surcharge] AS numeric(15,2)) AS
improvement_surcharge,
    CAST(t.[congestion_surcharge] AS numeric(15,2)) AS congestion_surcharge,
    CAST(t.[Airport_fee] AS numeric(15,2)) AS airport_free,
    CAST(t.[trip_distance] AS numeric(15,2)) AS distance,
    CAST(t.[passenger_count] AS numeric(15,0)) AS passenger,
    CAST(DATEDIFF(SECOND, t.tpep_pickup_datetime, t.tpep_dropoff_datetime)
AS numeric(18,0)) AS duration,
    CAST(t.[fare_amount] AS numeric(15,2)) AS fare_amount,
    CAST(t.[total_amount] AS numeric(15,2)) AS total_amount

FROM
    [dbo].[STG_TRIPS] t
LEFT JOIN [dbo].[DIM_VENDOR] v
    ON t.[VendorID] = v.[vendorID]
LEFT JOIN [dbo].[DIM_TIME] pickup_time
    ON CAST(t.[tpep_pickup_datetime] AS datetime) = pickup_time.[date]
LEFT JOIN [dbo].[DIM_TIME] dropoff_time
    ON CAST(t.[tpep_dropoff_datetime] AS datetime) = dropoff_time.[date]
```



```
LEFT JOIN [dbo].[DIM_LOCATION] pu_loc
    ON t.[PULocationID] = pu_loc.[locationID]
LEFT JOIN [dbo].[DIM_LOCATION] do_loc
    ON t.[DOLocationID] = do_loc.[locationID]
LEFT JOIN [dbo].[DIM_PAYMENT] p
    ON t.[payment_type] = p.[PaymentID]
LEFT JOIN [dbo].[DIM_RATE] r
    ON t.[RatecodeID] = r.[rateID]

-- Filtro para registros con VendorID no nulo
WHERE t.[VendorID] IS NOT NULL;
```

Durante el proceso de carga de datos en la tabla `FACT_NYTAXI_TRIP`, identifiqué un problema relacionado con el diseño de la estructura de la tabla, específicamente en los campos `extra`, `mta_tax`, `tip_amount`, `tolls_amount`, `improvement_surcharge`, `congestion_surcharge` y `airport_free`. Estos campos fueron definidos como `char(1)`, lo cual no es adecuado para almacenar los datos numéricos con decimales que se están procesando desde la fuente.

Problema identificado

El error principal surgió al intentar insertar valores numéricos (por ejemplo, `1.750000`) en columnas que están configuradas como cadenas de texto de un solo carácter (`char(1)`). Esto generó un conflicto de tipo, resultando en el siguiente mensaje de error: **"Error de desbordamiento aritmético para el tipo varchar, valor = 1.750000."**

Tras analizar el origen del problema, concluí que la definición de estos campos como `char(1)` no está alineada con la naturaleza de los datos que se pretende almacenar. Los valores numéricos con decimales, como los impuestos y tarifas, requieren un tipo de datos numérico, como `numeric(p, s)` o `float`.

Solución aplicada

Para resolver el problema, planteé dos posibles soluciones:

1. Modificar la estructura de la tabla `FACT_NYTAXI_TRIP`

Propuse ajustar los tipos de datos de los campos mencionados para que reflejen correctamente la naturaleza de los datos. Esto se llevó a cabo mediante las siguientes instrucciones SQL:

```
ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [extra] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [mta_tax] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [tip_amount] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [tolls_amount] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [improvement_surcharge] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [congestion_surcharge] numeric(15, 2);

ALTER TABLE [dbo].[FACT_NYTAXI_TRIP]
ALTER COLUMN [airport_free] numeric(15, 2);
```

Esta solución permitió que las columnas aceptaran valores numéricos con hasta 15 dígitos y 2 decimales, resolviendo el conflicto de tipos.

2. Ajustar la transformación de datos (opcional)

En caso de no poder modificar la estructura de la tabla destino, planteé una alternativa para ajustar el SQL de inserción. Este enfoque implica redondear los valores numéricos a enteros y convertirlos en cadenas de un solo carácter (`char(1)`). Aunque esta opción resolvía el problema técnico, la descarté debido a la pérdida de precisión en los datos, lo que no es ideal en un sistema de análisis.

Recomendación final

Implementé la primera solución, modificando la estructura de la tabla para que los tipos de datos sean consistentes con la naturaleza de los valores a almacenar. Este enfoque no solo resolvió el problema inmediato, sino que también asegura una mejor alineación con las buenas prácticas de diseño de bases de datos, evitando errores similares en futuras cargas.

Lección aprendida

Este caso resalta la importancia de alinear el diseño de la base de datos con la naturaleza de los datos que se procesarán. Definir correctamente los tipos de datos desde el principio no solo mejora la integridad de los datos, sino que también reduce el tiempo necesario para resolver problemas durante la integración.

Transformaciones para TR_FACT_FHV_TRIP

Para llenar la tabla de hechos `FACT_FHV_TRIP`, aproveché todas las validaciones y comprobaciones que ya realicé previamente para la tabla de taxis amarillos (`FACT_NYTXI_TRIP`). Este proceso fue más sencillo porque ya tenía las dimensiones listas y estructuradas.

1. Diseñé el flujo en Pentaho:

- Usé un componente `Table Input` donde coloqué la consulta SQL que filtra solo los registros con `VendorID IS NULL` desde la tabla staging `STG_TRIPS`.
- En el paso `Select Values`, ajusté las columnas para que coincidan con los campos de la tabla de hechos, asegurándome de mapear correctamente las claves foráneas y las métricas, como `duration`.

2. Estructura del flujo:

- Extraje los datos de `STG_TRIPS`, los procesé, y luego los dirigí hacia la salida (`Table Output`) para preparar la carga final.

3. Resultado:

- Este flujo generó los datos listos para la tabla `FACT_FHV_TRIP`, diferenciándola claramente de los taxis amarillos gracias al filtro de `VendorID IS NULL`. Fue rápido y eficiente porque reutilicé la lógica ya validada.

```
SELECT
    ROW_NUMBER() OVER (ORDER BY t.tpep_pickup_datetime) AS fhv_trip_id,

    l.licenseID AS licenseID,
    pickup_time.timeID AS pickup_datetimeID,
    dropoff_time.timeID AS dropoff_datetimeID,
    pu_loc.locationID AS PULocationID,
    do_loc.locationID AS DOLocationID,
    t.SR_Flag AS SR_flag,

    -- En lugar de CAST..., hacemos el JOIN y tomamos aff.licenseID
    aff.licenseID AS Affiliated_num,

    NULL AS fhv_trip,
```

```

        CAST(DATEDIFF(SECOND, t.tpep_pickup_datetime, t.tpep_dropoff_datetime)
AS numeric(18,0)) AS duration

FROM [dbo].[STG_TRIPS] t

-- JOIN principal para 'dispatching_base_num'
LEFT JOIN [dbo].[DIM_LICENSE] l
    ON 'B' + RIGHT(
        REPLICATE('0',5) + LTRIM(RTRIM(t.dispatching_base_num)),
        5
    ) = l.license_num

-- JOIN para 'Affiliated_base_number'
LEFT JOIN [dbo].[DIM_LICENSE] aff
    ON 'B' + RIGHT(
        REPLICATE('0',5) + LTRIM(RTRIM(t.Affiliated_base_number)),
        5
    ) = aff.license_num

-- JOIN con DIM_TIME
LEFT JOIN [dbo].[DIM_TIME] pickup_time
    ON CAST(t.tpep_pickup_datetime AS datetime) = pickup_time.[date]


LEFT JOIN [dbo].[DIM_TIME] dropoff_time
    ON CAST(t.tpep_dropoff_datetime AS datetime) = dropoff_time.[date]

-- JOIN con DIM_LOCATION
LEFT JOIN [dbo].[DIM_LOCATION] pu_loc
    ON t.PULocationID = pu_loc.locationID

LEFT JOIN [dbo].[DIM_LOCATION] do_loc
    ON t.DOLocationID = do_loc.locationID

WHERE
    t.VendorID IS NULL
    AND t.dispatching_base_num IS NOT NULL
    AND t.dispatching_base_num != ''
    -- Filtramos registros donde NO haya licencia de dispatch:
    AND l.licenseID IS NOT NULL
    -- Filtramos registros donde NO haya licencia afiliada (si es
obligatorio):
    AND aff.licenseID IS NOT NULL;

```



Execution Results

Logging	Execution History	Step Metrics	Performance Graph	Metrics	Preview data
<div> </div> <div>2024/12/23 23:40:31 - Select values.0 - linenr 5300000 2024/12/23 23:40:37 - TR_FACT_FHV_TRIP.0 - linenr 5300000 2024/12/23 23:40:48 - Table input.0 - !TableInput.Log.LineNumber! 2024/12/23 23:40:53 - Select values.0 - linenr 5350000 2024/12/23 23:40:57 - TR_FACT_FHV_TRIP.0 - linenr 5350000 2024/12/23 23:41:09 - Table input.0 - !TableInput.Log.LineNumber! 2024/12/23 23:41:13 - Select values.0 - linenr 5400000 2024/12/23 23:41:17 - TR_FACT_FHV_TRIP.0 - linenr 5400000 2024/12/23 23:41:26 - Table input.0 - !TableInput.Log.LineNumber! 2024/12/23 23:41:31 - Select values.0 - linenr 5450000 2024/12/23 23:41:37 - TR_FACT_FHV_TRIP.0 - linenr 5450000 2024/12/23 23:41:43 - Table input.0 - !TableInput.Log.FinishedReadingQuery! 2024/12/23 23:41:43 - Table input.0 - Finished processing (I=5479080, O=0, R=0, W=5479080, U=0, E=0) 2024/12/23 23:41:50 - Select values.0 - Finished processing (I=0, O=0, R=5479080, W=5479080, U=0, E=0) 2024/12/23 23:41:58 - TR_FACT_FHV_TRIP.0 - Finished processing (I=0, O=5479080, R=5479080, W=5479080, U=0, E=0) 2024/12/23 23:41:58 - Spoon - The transformation has finished!!</div>					

SQLQuery5.sql - UC...T_vnaranjom (116))
SQLQuery2.sql - UC...T_vnaranjom (101))*

```

/***** Script for SelectTopNRRows command from SSMS *****/
SELECT TOP (1000) [fhv_trip_id]
      ,[licenseID]
      ,[pickup_datetimeID]
      ,[dropoff_datetimeID]
      ,[PULocationID]
      ,[DOLocationID]
      ,[SR_flag]
      ,[Affiliated_num]
      ,[fhv_trip]
      ,[duration]
FROM [SOURCE_vnaranjom].[dbo].[FACT_FHV_TRIP]

```

100 %

Results


Messages

	fhv_trip_id	licenseID	pickup_datetimeID	dropoff_datetimeID	PULocationID	DOLocationID	SR_flag	Affiliated_num	fhv_trip	duration
1	1	1340	1696111200000	1696112055000	NULL	167	NULL	3021	NULL	855
2	2	2968	1696111200000	1696112055000	NULL	167	NULL	3021	NULL	855
3	3	8	1696111200000	1696111980000	NULL	NULL	NULL	8	NULL	780
4	4	8	1696111200000	1696113240000	NULL	NULL	NULL	8	NULL	2040
5	5	9	1696111200000	1696111980000	NULL	NULL	NULL	9	NULL	780
6	6	227	1696111200000	1696114560000	NULL	NULL	NULL	227	NULL	3360
7	7	1338	1696111206000	1696112097000	NULL	119	NULL	1338	NULL	891
8	8	3033	1696111207000	1696111509000	NULL	96	NULL	3033	NULL	302
9	9	937	1696111210000	1696112307000	NULL	159	NULL	3404	NULL	1097
10	10	937	1696111216000	1696111652000	NULL	119	NULL	3404	NULL	436
11	11	1338	1696111231000	1696112255000	NULL	213	NULL	1338	NULL	1024
12	12	1738	1696111233000	1696111854000	NULL	82	NULL	1738	NULL	621
13	13	3285	1696111233000	1696111976000	53	53	NULL	235	NULL	743
14	14	2968	1696111236000	1696112348000	NULL	78	NULL	2968	NULL	1112
15	15	1340	1696111236000	1696112348000	NULL	78	NULL	2968	NULL	1112
16	16	14	1696111238000	1696119000000	NULL	NULL	NULL	888	NULL	7762

Query executed successfully.

Creación de JOBS

JOB_IN_TAXIS_ZONE



Execution Results

Job / Job Entry	Comment	Result	Reason	Filename	Nr	Log date
Job: JOB_IN_TAXI_ZONES						
Start	Start of job execution		start			2024/12/20 12:56:28
Start	Job execution finished	Success			0	2024/12/20 12:56:28
IN_TAXI_ZONES	Start of job execution		Followed unconditional link			2024/12/20 12:56:28
IN_TAXI_ZONES	Job execution finished	Success			1	2024/12/20 12:56:28
Success	Start of job execution		Followed link after success			2024/12/20 12:56:28
Success	Job execution finished	Success			1	2024/12/20 12:56:28
Job: JOB_IN_TAXI_ZONES	Job execution finished	Success	finished		1	2024/12/20 12:56:28

Comentario sobre la Ejecución del Job: JOB_IN_TAXI_ZONES

La ejecución del Job **JOB_IN_TAXI_ZONES** muestra resultados exitosos en todas las etapas, como se detalla en los logs de ejecución:

1. Inicio del Job:

- El Job inició correctamente a las **12:56:28** , indicando que todas las configuraciones iniciales estaban adecuadamente establecidas.

2. Paso **Start** :

- Este paso inicializa el flujo del Job, confirmando que no hay errores en la configuración general del mismo.

3. Transformación **IN_TAXI_ZONES** :

- La transformación principal del Job, que lee y carga los datos desde el archivo fuente **taxi_zone_lookup.csv** a la tabla **STG_TAXI_ZONES** , se completó con éxito.
- No se encontraron errores durante la ejecución de este paso, lo que indica que el archivo fuente y los mapeos entre campos están correctamente definidos.

4. Paso **Success** :

- Este paso finalizó el Job, confirmando que todas las operaciones previas se ejecutaron sin problemas y que el flujo general del Job concluyó como estaba planeado.

5. Resultado General:

- El estado final del Job es **Success**, lo que valida que los datos fueron procesados y cargados correctamente en el almacén intermedio (**STG**).

Compruebo en la base de datos

UCS1R1UOCSQL01....o.STG_TAXI_ZONESSQLQuery1.sql - U...NT_vnaranjom (97))* X

/***** Script for SelectTopNRows command from SSMS *****/

SELECT *

FROM [SOURCE_vnaranjom].[dbo].[STG_TAXI_ZONES]

100 %

Results

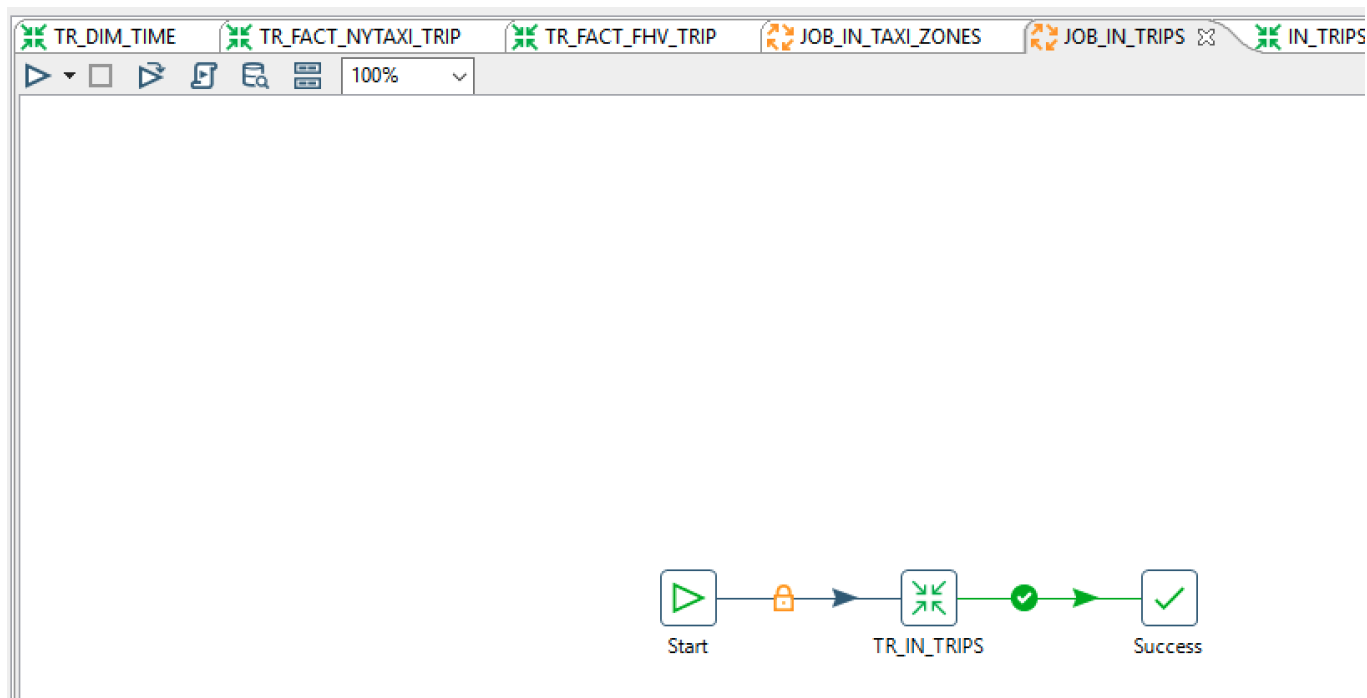
Messages

	LocationID	Borough	Zone	Service_zone
236	236	Manhattan	Upper East Side North	Yellow Zone
237	237	Manhattan	Upper East Side South	Yellow Zone
238	238	Manhattan	Upper West Side North	Yellow Zone
239	239	Manhattan	Upper West Side South	Yellow Zone
240	240	Bronx	Van Cortlandt Park	Boro Zone

JOB_IN_TRIPS

Este es el **job maestro** que diseñé para orquestar la ejecución de las transformaciones relacionadas con los viajes (**TR_IN_TRIPS**). El flujo inicia con un paso de **inicio (Start)**, que asegura que todas las dependencias estén listas. Luego, se ejecuta la transformación principal **TR_IN_TRIPS** , que integra los datos necesarios para las tablas de hechos. Finalmente, el proceso termina con un paso de **éxito (Success)** que marca el job como completado correctamente.

Este diseño asegura que todo se ejecute en orden y sin errores, permitiendo una gestión centralizada y eficiente de las transformaciones relacionadas con los datos de viajes.

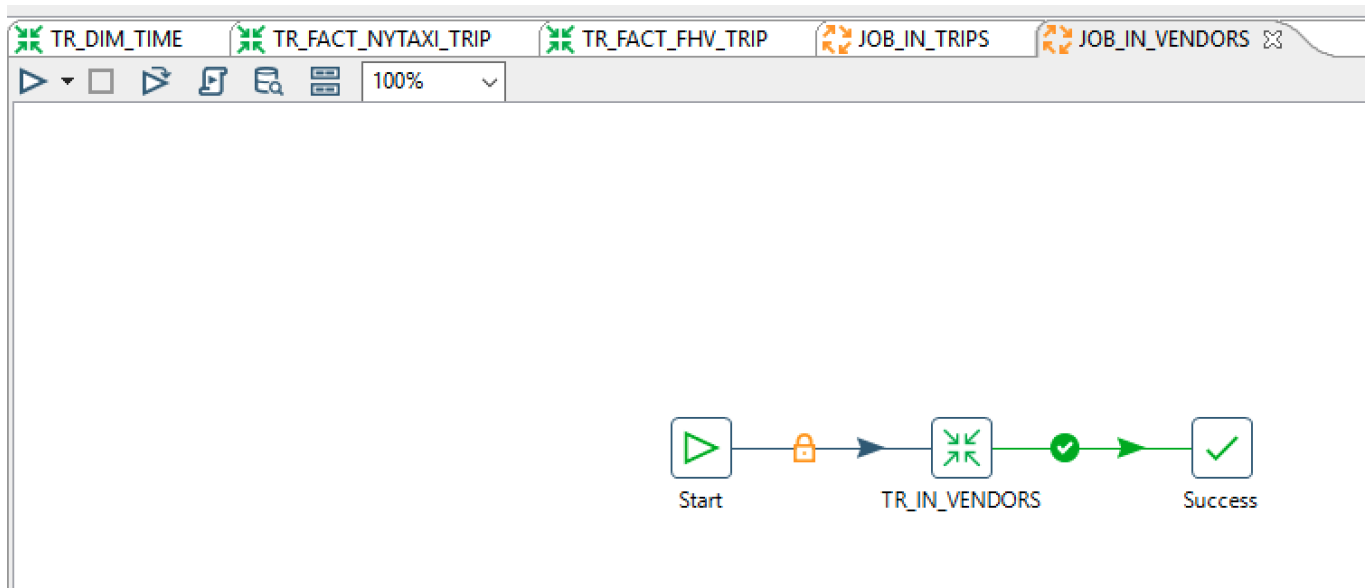


JOB_IN_VENDORS

En este caso, el **job maestro** **JOB_IN_VENDORS** se utiliza para gestionar la ejecución de la transformación relacionada con la carga de datos de proveedores (**TR_IN_VENDORS**).

1. **Inicio (Start)**: Este paso asegura que el proceso comience solo cuando todas las dependencias necesarias estén disponibles y listas.
2. **Transformación (TR_IN_VENDORS)**: Aquí se ejecuta la transformación que procesa los datos de los proveedores, mapeando y transformando los datos según las dimensiones y requisitos definidos.
3. **Finalización (Success)**: Este paso valida que todo el flujo se haya ejecutado correctamente y marca el job como exitoso.

Con este flujo simple pero efectivo, garantizo que los datos de proveedores sean procesados de manera autónoma y sin errores, siguiendo la misma lógica modular que en los otros jobs.



JOB_IN_PAYMENTS

En este caso, el **job** **JOB_IN_PAYMENTS** sigue el mismo patrón que los jobs anteriores, pero está enfocado en la carga y procesamiento de los datos relacionados con los métodos de pago.

1. Inicio (**Start**):

- Este paso asegura que el proceso comience de manera controlada, verificando que el flujo esté listo para ejecutarse.

2. Transformación (**TR_IN_PAYMENTS**):

- Aquí se realiza el procesamiento de los datos de métodos de pago. Se extraen, transforman y ajustan los datos desde la fuente para que encajen correctamente en la tabla de dimensión correspondiente.

3. Finalización (**Success**):

- Este paso valida que el job haya terminado con éxito, marcándolo como completo y sin errores.

Con este flujo modular, se garantiza que los datos de métodos de pago sean procesados y cargados correctamente, siguiendo una estructura clara y reutilizable en el ETL.



JOB_IN_RATES

Este es el **job** `JOB_IN_RATES`, diseñado para manejar la carga y transformación de datos relacionados con las tarifas (`TR_IN_RATES`).

1. Inicio (`Start`):

- Marca el inicio del proceso, asegurando que todos los elementos necesarios estén en orden para ejecutar la transformación.


2. Transformación (`TR_IN_RATES`):

- Este paso procesa los datos de tarifas, ajustándolos para que cumplan con la estructura y requisitos de la tabla de dimensión de tarifas. Aquí se realizan las conversiones y mapeos necesarios.

3. Finalización (`Success`):

- Indica que el proceso ha sido exitoso, confirmando que todos los datos fueron procesados sin errores.

El flujo es simple pero efectivo, garantizando que las tarifas sean procesadas correctamente y que el pipeline ETL mantenga su integridad y consistencia.



JOB_TR_DIM_LOCATION

Este es el **job JOB_TR_DIM_LOCATION**, que se encarga de la carga y transformación de datos relacionados con la dimensión de ubicaciones.

1. Inicio (Start):

- Este paso inicia el proceso y verifica que todo esté listo para ejecutar la transformación.


2. Transformación (TR_DIM_LOCATION):

- Aquí se procesan los datos de ubicaciones, transformándolos y mapeándolos para que coincidan con la estructura de la tabla de dimensión **DIM_LOCATION**. Esto incluye la validación de datos, asignación de claves y ajuste de formatos.

3. Finalización (Success):

- Este paso marca el final del proceso y confirma que la transformación se ejecutó correctamente sin errores.

Este flujo garantiza que la dimensión de ubicaciones sea construida y cargada de manera eficiente, asegurando que los datos estén listos para ser usados en los análisis posteriores.



JOB_TR_DIM_VENDOR

Este es el **job** **JOB_TR_DIM_VENDOR** , utilizado para la carga y transformación de datos relacionados con los conductores (**DIM_VENDOR**).

1. Inicio (**Start**):

- Se asegura de que el proceso comience correctamente, verificando que todo esté preparado antes de la ejecución.

2. Transformación (**TR_DIM_VENDOR**):

- Este paso realiza la transformación de los datos de proveedores, validando y mapeando la información necesaria para que cumpla con la estructura de la tabla **DIM_VENDOR** . Aquí se procesan las claves y los datos relacionados con los nombres de los proveedores.

3. Finalización (**Success**):

- Este paso confirma que la transformación fue exitosa y que los datos están listos para ser utilizados en las tablas de hechos u otras dimensiones.

Con este flujo modular, garantizo que los datos de los proveedores se procesen de forma correcta y eficiente, asegurando la calidad de los datos para su posterior análisis.



JOB_TR_DIM_PAYMENT

Este es el **job JOB_TR_DIM_PAYMENT**, diseñado para manejar la carga y transformación de la dimensión relacionada con los métodos de pago.

1. Inicio (Start):

- Este paso marca el inicio del proceso, asegurándose de que todo esté listo antes de proceder con la transformación.

2. Transformación (TR_DIM_PAYMENT):

- Aquí se procesan los datos relacionados con los métodos de pago. La transformación valida y ajusta los datos para que coincidan con la estructura de la tabla de dimensión `DIM_PAYMENT`, asignando correctamente claves y ajustando formatos si es necesario.

3. Finalización (Success):

- Indica que el proceso ha sido completado correctamente, asegurando que los datos de los métodos de pago estén listos y sin errores.

Con este flujo, la dimensión de métodos de pago se gestiona de forma eficiente, permitiendo que los datos estén disponibles para su uso en las tablas de hechos.



JOB_TR_DIM_RATE

Este es el **job JOB_TR_DIM_RATE**, encargado de la carga y transformación de datos para la dimensión de tarifas (**DIM_RATE**).

1. Inicio (**Start**):

- Marca el inicio del proceso, asegurando que todas las condiciones previas estén listas antes de ejecutar la transformación.


2. Transformación (**TR_DIM_RATE**):

- En este paso, se procesan los datos relacionados con las tarifas. Aquí se validan y transforman los registros para adaptarlos a la estructura de la tabla **DIM_RATE**, asegurando que los datos sean consistentes y estén correctamente formateados.

3. Finalización (**Success**):

- Indica que el proceso se completó con éxito, garantizando que los datos de tarifas están listos para ser utilizados en análisis o integrados en las tablas de hechos.

Este flujo es fundamental para que la dimensión de tarifas esté correctamente cargada y disponible para su uso en el modelo de datos.



JOB_TR_DIM_TIME

Este es el **job JOB_TR_DIM_TIME**, encargado de procesar y cargar la dimensión de tiempo (DIM_TIME).

1. Inicio (Start):

- Este paso asegura que el proceso comience de manera ordenada, verificando que todas las condiciones iniciales estén listas para la ejecución.


2. Transformación (TR_DIM_TIME):

- Aquí se procesan los datos relacionados con fechas y tiempos. La transformación genera los registros necesarios, desglosando los componentes de fecha y hora (año, mes, día, hora, minuto, segundo) y los ajusta a la estructura de la tabla DIM_TIME . Esto permite análisis temporales detallados.

3. Finalización (Success):

- Este paso valida que el proceso se haya completado correctamente, marcando el job como exitoso y asegurando que los datos de la dimensión de tiempo estén listos para su uso.

Este flujo es esencial para garantizar que la dimensión de tiempo esté correctamente estructurada y disponible para el análisis en las tablas de hechos.



JOB_TR_DIM_LICENSE

Este es el **job JOB_TR_DIM_LICENSE**, encargado de la carga y transformación de datos relacionados con la dimensión de licencias (**DIM_LICENSE**).

1. Inicio (**Start**):

- Este paso inicial asegura que el proceso comience correctamente, validando que todo esté preparado para la transformación.


2. Transformación (**TR_DIM_LICENSE**):

- En este paso, se procesan los datos de licencias. La transformación valida y ajusta los datos para que coincidan con la estructura de la tabla **DIM_LICENSE**, garantizando que los registros sean consistentes y se asignen correctamente las claves de licencia y otros detalles asociados.

3. Finalización (**Success**):

- Este paso marca que el proceso se completó exitosamente, asegurando que los datos de la dimensión de licencias estén listos para integrarse en las tablas de hechos y análisis posteriores.

Con este flujo modular, los datos de licencias son procesados eficientemente, asegurando su calidad y disponibilidad para el modelo de datos.



JOB_TR_FACT_NYTAXI_TRIP

Este es el **job** `JOB_TR_FACT_NYTAXI_TRIP` , diseñado para procesar y cargar los datos en la tabla de hechos `FACT_NYTAXI_TRIP` .

1. Inicio (Start):

- Marca el inicio del proceso, verificando que todas las dependencias estén listas antes de proceder con la transformación.


2. Transformación (TR_FACT_NYTAXI_TRIP):

- En este paso, se procesan los datos de viajes de taxis amarillos. La transformación combina información de las dimensiones relacionadas (ubicación, tiempo, proveedor, entre otras) y calcula métricas clave como duración, distancia y montos. Esto asegura que los datos estén listos y correctamente estructurados para la tabla de hechos.

3. Finalización (Success):

- Este paso confirma que el proceso se completó exitosamente, indicando que los datos se cargaron correctamente en la tabla de hechos.

Con este flujo, los datos de los viajes de taxis amarillos se integran de manera eficiente, proporcionando una base sólida para análisis y reportes posteriores.



JOB_TR_FACT_FHV_TRIP

Este es el **job** `JOB_TR_FACT_FHV_TRIP`, diseñado para procesar y cargar los datos en la tabla de hechos `FACT_FHV_TRIP`.

1. Inicio (`Start`):

- Marca el comienzo del proceso, verificando que todas las condiciones necesarias estén listas para ejecutar la transformación.


2. Transformación (`TR_FACT_FHV_TRIP`):

- En este paso, se procesan los datos correspondientes a los viajes de FHV (For-Hire Vehicles). La transformación filtra los registros donde `VendorID` es nulo, mapea las claves de las dimensiones (tiempo, ubicación, licencias) y calcula métricas como la duración del viaje. Esto asegura que los datos estén listos para su integración en la tabla de hechos.

3. Finalización (`Success`):

- Este paso confirma que la transformación fue completada exitosamente y que los datos fueron preparados y estructurados adecuadamente.

Con este flujo, los datos de los viajes de FHV se integran de manera eficiente en la tabla de hechos, permitiendo análisis y reportes específicos para esta categoría de viajes.

 JOB_TR_FACT_FHV_TRIP 